

1.3 设 (H, \mathcal{B}, P) 是一个统计结构，证明：

(1) 若 H 只含有不多于可数个元素，则此结构是可控的；

(2) 若 P 只含有不多于可数个分布，则此结构是可控的。

解：(1) 对于任何的 $B \in \mathcal{B}$ ，在 (H, \mathcal{B}) 上定义：

$$m(B) = \{B \text{ 中元素的个数} \}$$

① 这样定义的 m 是有意义的，因为对于任何的 $B \in \mathcal{B}$ ， B 是可数集。

② 这样定义的 m 满足非负性、规范性和完全可加性，所以是一个测度。

③ 这样定义的 m 是一个 σ 有限测度，因为全集 H 可以看作是至多可数个单点集的并，而在每个单点集上， m 测得的测度为 1。

对于任何的 $N \in \mathcal{B}$ ，如果 $m(N)=0$ ，则 $N = \emptyset$ ，所以对于任何的 $P \in \mathcal{P}$ ，由于概率测度的正规性，所以 $P(N)=0$ ，所以该结构可控。

(2) 对于任何的 $B \in \mathcal{B}$ ，在 (H, \mathcal{B}) 上定义：

$$n(B) = \sup \{P_k(B), P_k \in \mathcal{P}\}$$

① 这样定义的 n 是有意义的，因为对于任何的 $B \in \mathcal{B}$ ， B 是可数集。

② 这样定义的 n 满足非负性、规范性和完全可加性，所以是一个测度。

③ 这样定义的 n 是一个 σ 有限测度，因为 \mathcal{P} 只含有不多于可数个分布。

对于任何的 $N \in \mathcal{B}$ ，如果 $n(N)=0$ ，则 $\sup \{P_k(N), P_k \in \mathcal{P}\} = 0$ ，所以对于任何的 $P_k \in \mathcal{P}$ ， $P_k(N)=0$ ，所以该结构可控。

1.4 设随机变量 $X \sim \text{Ga}(a, \lambda)$ ，若 c 为正实数，证明 $cX \sim \text{Ga}(a, \frac{\lambda}{c})$ ，若 $X \sim \text{Ga}(5, 0.01)$ ，计算概率 $P(X > 200)$

解：(1) 因为 $c > 0, y = cx$ ，所以 $x = \frac{y}{c} (y > 0)$

$$\begin{aligned} P_Y(y) &= P_X\left(\frac{y}{c}\right) \frac{1}{c} = \frac{\lambda^a}{c\Gamma(a)} \left(\frac{y}{c}\right)^{a-1} \exp\left\{-\lambda \frac{y}{c}\right\} \\ &= \frac{\left(\frac{\lambda}{c}\right)^a}{\Gamma(a)} y^{a-1} \exp\left\{-\lambda \frac{y}{c}\right\} \end{aligned}$$

为 $\text{Ga}(a, \lambda)$ 的密度函数。所以得证

(2) 由已证结论： $X \sim \text{Ga}(5, 0.01)$ ，则 $Y = 0.01X \sim \text{Ga}(5, 1)$

$$P(X > 200) = P(Y > 2)$$

$$=1-P(Y \leq 2) = 1 - \int_0^2 \frac{1}{\Gamma(5)} x^4 e^{-x} dx$$

$$=1 - \frac{1}{24} \int_0^2 x^4 e^{-x} dx$$

$$=7e^{-2}$$

1.5

$$\text{解: } p(y; \alpha, \lambda, \mu) = \frac{\lambda^\alpha}{\Gamma(\alpha)} (y - \mu)^{\alpha-1} e^{-\lambda(y-\mu)}$$

$$\text{由于 } X \sim \text{Ga}(\alpha, \lambda), \text{ 故 } E(X) = \frac{\alpha}{\lambda}, \text{Var}(X) = \frac{\alpha}{\lambda^2}$$

$$E(Y) = E(X + \mu) = E(X) + \mu = \frac{\alpha}{\lambda} + \mu$$

$$\text{Var}(Y) = \text{Var}(X + \mu) = \text{Var}(X) = \frac{\alpha}{\lambda^2}$$

1.9 χ^2 分布函数表和 χ^2 分布的分位数表往往只对自由度 $n \leq 30$ 给出, 当 $n > 30$ 时可用正态分布近似, 计算

(1) 自由度为 **35** 的 χ^2 变量大于 **45** 的概率

(2) 自由度为 **40** 的 χ^2 分布的 **0.05** 分位数

解: (1) 设 $X \sim \chi^2(35)$, 则 $E(X) = n = 35$, $\text{Var}(X) = 2n = 70$

$$P(X > 45) = 1 - P(X \leq 45)$$

$$\approx 1 - \Phi\left(\frac{45 - 35}{\sqrt{70}}\right)$$

$$\approx 1 - \Phi\left(\frac{10}{\sqrt{70}}\right)$$

$$\approx 1 - 0.8830$$

$$\approx 0.117$$

(2) 设 $Y \sim \chi^2(40)$, 则 $E(Y) = n = 40$, $\text{Var}(Y) = 2n = 80$

$$P = 1 - 0.05 = 0.95, \text{ 则 } P(Y \leq Y_p) = 0.95$$

$$\text{则 } \Phi\left(\frac{Y_p - 40}{\sqrt{80}}\right) = 0.95$$

$$\frac{Y_p - 40}{\sqrt{80}} = 1.645$$

$$\text{则 } Y_p = 54.713$$

1.10 设随机变量 $X \sim \text{Ga}(\alpha, \lambda)$, 则 $Y = X^{-1}$ 服从倒 Gamma 分布, 请写出 Y 的密度函数, 并计算 $E(Y)$ 和 $\text{Var}(Y)$ 。

解: $\because X \sim \text{Ga}(\alpha, \lambda) \therefore X$ 的密度函数为

$$p(x) = \begin{cases} \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

由 $Y = X^{-1}$ 得

$$F_Y(y) = P(Y \leq y) = P\left(\frac{1}{X} \leq y\right) = P\left(X \geq \frac{1}{y}\right) = 1 - P\left(X < \frac{1}{y}\right)$$

$$= \begin{cases} 1 - \int_0^{\frac{1}{y}} \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x} dx, & \frac{1}{y} \geq 0 \\ 1, & \frac{1}{y} < 0 \end{cases}$$

$$p_Y(y) = F'_Y(y) = \begin{cases} \frac{\lambda^\alpha}{\Gamma(\alpha)} \left(\frac{1}{y}\right)^{\alpha+1} e^{-\frac{\lambda}{y}}, & y \geq 0 \\ 0, & y < 0 \end{cases}$$

$$E(Y) = \int_0^{+\infty} y \cdot \frac{\lambda^\alpha}{\Gamma(\alpha)} \left(\frac{1}{y}\right)^{\alpha+1} e^{-\frac{\lambda}{y}} dy = \int_0^{+\infty} \frac{\lambda^\alpha}{\Gamma(\alpha)} \left(\frac{1}{y}\right)^\alpha e^{-\frac{\lambda}{y}} dy$$

$$= \frac{\lambda \Gamma(\alpha-1)}{\Gamma(\alpha)} = \frac{\lambda}{\alpha-1} \quad (\alpha > 1)$$

$$E(Y^2) = \int_0^{+\infty} y^2 \cdot \frac{\lambda^\alpha}{\Gamma(\alpha)} \left(\frac{1}{y}\right)^{\alpha+1} e^{-\frac{\lambda}{y}} dy = \int_0^{+\infty} \frac{\lambda^\alpha}{\Gamma(\alpha)} \left(\frac{1}{y}\right)^{\alpha-1} e^{-\frac{\lambda}{y}} dy$$

$$= \int_0^{+\infty} \frac{\lambda^2 \Gamma(\alpha-2)}{\Gamma(\alpha)} \cdot \frac{\lambda^{\alpha-2} \left(\frac{1}{y}\right)^{\alpha-1}}{\Gamma(\alpha-2)} e^{-\frac{\lambda}{y}} dy = \frac{\lambda^2 \Gamma(\alpha-2)}{\Gamma(\alpha)}$$

$$= \frac{\lambda^2 \Gamma(\alpha-2)}{(\alpha-1)(\alpha-2) \Gamma(\alpha-2)} = \frac{\lambda^2}{(\alpha-1)(\alpha-2)} \quad (\alpha > 2)$$

$$\therefore \text{Var}(Y) = E(Y^2) - [E(Y)]^2 = \frac{\lambda^2}{(\alpha-1)(\alpha-2)} - \frac{\lambda^2}{(\alpha-1)^2} = \frac{\lambda^2}{(\alpha-1)^2(\alpha-2)} (\alpha > 2)$$

1.11 若随机变量 $X+c$ 和 $-X+c$ 有相同的分布, 则称随机变量的分布关于点 c 对称。

如果 X 有密度函数 $p(x)$, 则其关于点 c 对称的充要条件是 $p(x-c)=p(c-x), \forall x \in R$ 。

证明: 必要性: 随机变量 X 关于点 c 对称

$$\Rightarrow F(X+c) = F(-X+c) \Rightarrow P(X+c \leq t) = P(-X+c \leq t) \Rightarrow P(X \leq t-c) = P(X \geq c-t) = 1 - P(X < c-t)$$

$$\Rightarrow \int_{-\infty}^{t-c} p(t) dt = 1 - \int_{-\infty}^{c-t} p(t) dt$$

对上面等式左边换元, 令 $t = x-c$, 则左边 $= \int_{-\infty}^x p(x-c) dx$

对上面等式右边换元, 令 $t = c-x$, 则右边 $= 1 + \int_{+\infty}^x p(c-x) dx$

所以得出 $\int_{-\infty}^x p(x-c) dx = \int_{-\infty}^x p(c-x) dx$, 所以 $p(x-c) = p(c-x)$

充分性: 将上述过程逆推即可证得。

1.11 若随机变量 $X-c$ 和 $-X+c$ 有相同的分布, 则称随机变量的分布关于点 c 对称。

如果 X 有密度函数 $p(x)$, 则其关于点 c 对称的充要条件是 $p(x+c)=p(c-x), \forall x \in R$ 。

证明:

必要性: $\because X$ 的密度函数为 $p(x)$, 其关于点 c 对称, 从而 $X-c$ 与 $X+c$ 有相同的分布, 故概率密度函数相同, 即 $p(X-c)=p(X+c)$ 。

\therefore 对 $\forall x \in R$ 有 $p(x+c)=p(c-x)$ 。

充分性: 令 $Y=X-c, Z=-X+c$. $\because X$ 的密度函数为 $p(x)$, 则 Y 的密度函数为 $p(Y+c)$, Z 的密度函数为 $p(c-Z)$. 由已知, 对 $\forall x \in R$, 都有 $p(x+c)=p(c-x)$. 故对随机变量的一切取值, 都有 $p(z+c)=p(c-z)$. 即是 $p(Z+c) = p(c-Z)$, 其中 $p(Z+c)$ 就为 Y 的密度函数 (只是替换了变量)

从而, Y 与 Z 有相同的密度函数. 即 $X-c$ 和 $-X+c$ 有相同的分布。

\therefore 随机变量的分布关于点 c 对称。

1.15 证明下述结论。

(1) 设 $F(x)$ 为连续随机变量 X 的分布函数, 则 $Y=F(X) \sim U(0,1)$

(2) 设 $Y \sim U(0,1)$, 则 $u=-2\ln Y \sim \chi^2(2)$

(3) 设 X_1, \dots, X_n 是连续随机变量 X 的 n 次观察值, $F(x)$ 是 X 的分布函数, 则 $-2 \sum_{i=1}^n \ln F(X_i) \sim \chi^2(2n)$

证明: (1) 因为 $0 \leq F_x(x) \leq 1$, 所以

①当 $y < 0$ 时, $F_Y(y) = P\{Y \leq y\} = P\{F_X(x) \leq y\} = 0$

②当 $0 \leq y \leq 1$, $F_Y(y) = P\{Y \leq y\} = P\{F_X(x) \leq y\} = y$

③当 $y > 1$, $F_Y(y) = P\{Y \leq y\} = P\{F_X(x) \leq y\} = 1$

所以 $Y \sim U(0,1)$, 即证

(2) 设 $x = -2 \ln Y \sim \chi^2(2)$

$$\begin{aligned} F_X(x) &= P\{X \leq x\} \\ &= P\{-2 \ln Y \leq x\} \\ &= P\{Y \leq e^{-\frac{1}{2}x}\} \\ &= 1 - e^{-\frac{1}{2}x} \end{aligned}$$

所以 $F'_X(x) = f_X(x) = \frac{1}{2} e^{-\frac{1}{2}x} \sim \chi^2(2)$, 即证

(3) 因为 $-2 \sum_{i=1}^n \ln F(X_i)$

$$= \sum_{i=1}^n -2 \ln F(X_i)$$

由刚刚证得的 (2) 中结论可得 $-2 \ln F(x_i) \sim \chi^2(2)$

又由证得的 (1) 中结论 $Y = F(X) \sim U(0,1)$ 可得 $\sum_{i=1}^n -2 \ln F(X_i) \sim \chi^2(2n)$

所以 $-2 \sum_{i=1}^n \ln F(X_i) = \sum_{i=1}^n -2 \ln F(X_i) \sim \chi^2(2n)$, 即证

1.21. 设 $X \sim N_n(\mu, \Sigma)$, C 为任一 $r \times n$ 阶阵, 证明

$$CX \sim N_r(C\mu, C\Sigma C')$$

证明: 由 $X \sim N_n(\mu, \Sigma)$, 知 $X_i \sim N(\mu, \sigma_{ii}^2)$, 记

$$Y_j = c_{ji} X_i, \quad j=1, 2, \dots, r$$

则 Y_i 服从正态分布, $Y = CX$ 服从多元正态分布, 且

$$\begin{aligned} EY_j &= c_{ji} \mu_i \quad j=1, 2, \dots, r \\ DY_j &= c_{ji}^2 \sigma_{jj}^2 \quad j=1, 2, \dots, r \\ \text{COV}(Y_i, Y_j) &= c_{is} c_{jk} \text{COV}(X_s, X_k) \\ &= c_{is} c_{jk} \sigma_{sk} \end{aligned}$$

故 $Y = CX$ 的协方差矩阵为 $C\Sigma C'$

综上所述: $Y = CX \sim N_r(C\mu, C\Sigma C')$

1.22 设

$$X = \begin{pmatrix} X_1 \\ X_2 \end{pmatrix} \sim N_n \left(\begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix} \right)$$

其中 X_1 与 μ_1 都是 k 维向量, Σ_{11} 为 k 阶方阵, Σ_{12} , Σ_{21} , Σ_{22} 为相应矩阵, 且

$|\Sigma_{22}| \neq 0$, 证明

(1) $X_1 \sim N_k(\mu_1, \Sigma_{11});$

(2) X_1 与 X_2 相互独立的充分必要条件是 $\Sigma_{12} = 0$;

(3) 在给定 $X_2 = x_2$ 下, X_1 的条件分布是

$$N_k(\mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(x_2 - \mu_2), \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21})$$

证明:

(1) 设

$$X \sim N_n(\mu, \Sigma), \text{ 其中, } \mu = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \Sigma = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix}, t = \begin{pmatrix} t_1 \\ t_2 \end{pmatrix}$$

X 的特征函数为

$$\begin{aligned} f_X(t) &= E(e^{it'X}) \\ &= \exp \left\{ it'\mu - \frac{1}{2} t'\Sigma t \right\} \\ &= \exp \left\{ it'_1\mu_1 + it'_2\mu_2 - \frac{1}{2} (t'_1\Sigma_{11}t_1 + t'_1\Sigma_{12}t_2 + t'_2\Sigma_{21}t_1 + t'_2\Sigma_{22}t_2) \right\} \end{aligned}$$

令 $t_2 = 0$, 则可以得到 X_1 的特征函数为

$$f_1(t_1) = \exp \left\{ it'_1\mu_1 - \frac{1}{2} t'_1\Sigma_{11}t_1 \right\}$$

$$\therefore X_1 \sim N_k(\mu_1, \Sigma_{11})$$

(2)

$$\begin{aligned} (\Rightarrow) \quad f(t_1, t_2) &= \exp \left\{ it'\mu - \frac{1}{2} t'\Sigma t \right\} \\ &= \exp \left\{ it'_1\mu_1 + it'_2\mu_2 - \frac{1}{2} (t'_1\Sigma_{11}t_1 + t'_1\Sigma_{12}t_2 + t'_2\Sigma_{21}t_1 + t'_2\Sigma_{22}t_2) \right\} \end{aligned}$$

$\therefore X_1$ 与 X_2 相互独立

$$\begin{aligned}\therefore f(t_1, t_2) &= f(t_1) \cdot f(t_2) \\ &= \exp \left\{ i t'_1 \mu_1 + i t'_2 \mu_2 - \frac{1}{2} (t'_1 \Sigma_{11} t_1 + t'_2 \Sigma_{22} t_2) \right\}\end{aligned}$$

对比上述两式可得

$$t'_1 \Sigma_{12} t_2 + t'_2 \Sigma_{21} t_1 = 0$$

$$\text{又} \therefore (t'_1 \Sigma_{12} t_2) = t'_2 \Sigma_{21} t_1$$

$$\therefore t'_1 \Sigma_{12} t_2 = 0$$

$$\therefore \Sigma_{12} = 0$$

$$(\Leftarrow) \therefore \Sigma_{12} = 0$$

$$\therefore f(t_1, t_2) = \exp \left\{ i t' \mu - \frac{1}{2} t' \Sigma t \right\}$$

$$\begin{aligned}&= \exp \left\{ i t'_1 \mu_1 + i t'_2 \mu_2 - \frac{1}{2} (t'_1 \Sigma_{11} t_1 + t'_1 \Sigma_{12} t_2 + t'_2 \Sigma_{21} t_1 + t'_2 \Sigma_{22} t_2) \right\} \\ &= \exp \left\{ i t'_1 \mu_1 - \frac{1}{2} t'_1 \Sigma_{11} t_1 \right\} \cdot \exp \left\{ i t'_2 \mu_2 - \frac{1}{2} t'_2 \Sigma_{22} t_2 \right\} \\ &= f_{X_1}(t_1) \cdot f_{X_2}(t_2)\end{aligned}$$

$\therefore X_1$ 与 X_2 相互独立

$$(3) \text{ 令 } \begin{cases} Y_1 = X_1 + A X_2 \\ Y_2 = X_2 \end{cases}, \text{ 令 } Y_1 \text{ 与 } Y_2 \text{ 相互独立}$$

则 Y_1 与 Y_2 服从联合正太分布，且 $\text{cov}(Y_1, Y_2) = 0$

$$\begin{aligned}\text{cov}(Y_1, Y_2) &= E(Y_1 Y'_2) - E(Y_1) \cdot E(Y'_2) \\ &= E[(X_1 + A X_2) X'_2] - (\mu_1 + A \mu_2) \mu'_2 \\ &= [E(X_1 X'_2) - \mu_1 \mu'_2] + A [E(X_2 X'_2) - \mu_2 \mu'_2] \\ &= \Sigma_{12} + A \Sigma_{22} \\ &= 0\end{aligned}$$

$$\therefore A = -\Sigma_{12}\Sigma_{22}^{-1}, \quad Y_1 = X_1 - \Sigma_{12}\Sigma_{22}^{-1}X_2$$

$$\therefore p(X_1, X_2) = p(Y_1, Y_2) \cdot |J| = p(Y_1, Y_2) = p(Y_1) \cdot p(Y_2)$$

$$\text{则} \quad p(X_1 | X_2) = \frac{p(X_1, X_2)}{p(X_2)} = \frac{p(Y_1)p(Y_2)}{p(Y_2)} = p(Y_1) = p(X_1 - \Sigma_{12}\Sigma_{22}^{-1}X_2)$$

$$\therefore E(X_1 - \Sigma_{12}\Sigma_{22}^{-1}X_2) = E(X_1) - \Sigma_{12}\Sigma_{22}^{-1}E(X_2)$$

$$= \mu_1 - \Sigma_{12}\Sigma_{22}^{-1}\mu_2$$

$$\text{var}(X_1 - \Sigma_{12}\Sigma_{22}^{-1}X_2) = \text{var}(X_1) + \Sigma_{12}\Sigma_{22}^{-1}\text{var}(X_2)(\Sigma_{12}\Sigma_{22}^{-1})' - 2\Sigma_{12}\Sigma_{22}^{-1}\text{cov}(X_1, X_2)$$

$$= \Sigma_{11} + \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{22}\Sigma_{22}^{-1}\Sigma_{12}' - 2\Sigma_{12}\Sigma_{22}^{-1}\Sigma_{12}'$$

$$= \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{12}'$$

\therefore 在给定 $X_2 = x_2$ 下, X_1 的条件分布是

$$N_k(\mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(x_2 - \mu_2), \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{12}')$$

1.26 设 $\begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \sim N_2\left[\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix}\right]$, 证明

$$Y_1 = \frac{X_1 - \mu_1}{\sigma_1}, \quad Y_2 = \frac{1}{\sqrt{1-\rho^2}} \left(\frac{X_2 - \mu_2}{\sigma_2} - \rho \frac{X_1 - \mu_1}{\sigma_1} \right)$$

为相互独立的标准正态变量。

证明：因为 $X_i \sim N(\mu_i, \sigma_i^2)$, $i = 1, 2$, $r = \text{cov}(X_1, X_2) / (\sigma_1\sigma_2)$, $\sigma_1\sigma_2 \neq 0$, 所以

$$\frac{X_i - \mu_i}{\sigma_i} \sim N(0, 1), \quad i = 1, 2, \text{ 从而 } Y_1 = \frac{X_1 - \mu_1}{\sigma_1} \sim N(0, 1)。$$

又因为 Y_2 是正态变量的线性变换仍是正态变量且

$$\begin{aligned} EY_2 &= E\left(\frac{1}{\sqrt{1-\rho^2}}\left(\frac{X_2 - \mu_2}{\sigma_2} - \rho\frac{X_1 - \mu_1}{\sigma_1}\right)\right) \\ &= \frac{1}{\sqrt{1-\rho^2}}\left(E\left(\frac{X_2 - \mu_2}{\sigma_2}\right) - \rho E\left(\frac{X_1 - \mu_1}{\sigma_1}\right)\right) \\ &= 0 \end{aligned}$$

$$\begin{aligned}
DY_2 &= D\left(\frac{1}{\sqrt{1-\rho^2}}\left(\frac{X_2-\mu_2}{\sigma_2}-\rho\frac{X_1-\mu_1}{\sigma_1}\right)\right) \\
&= \left(\frac{1}{\sqrt{1-\rho^2}}\right)^2 D\left(\frac{X_2-\mu_2}{\sigma_2}-\rho\frac{X_1-\mu_1}{\sigma_1}\right) \\
&= \frac{1}{1-\rho^2}\left(D\left(\frac{X_2-\mu_2}{\sigma_2}\right)-\rho^2 D\left(\frac{X_1-\mu_1}{\sigma_1}\right)\right) \\
&= \frac{1}{1-\rho^2}(1-\rho^2) \\
&= 1
\end{aligned}$$

所以 $Y_2 = \frac{1}{\sqrt{1-\rho^2}}\left(\frac{X_2-\mu_2}{\sigma_2}-\rho\frac{X_1-\mu_1}{\sigma_1}\right) \sim N(0,1)$ 。

Y_1, Y_2 是标准正态变量，则 Y_1 与 Y_2 独立的充要条件是 Y_1 与 Y_2 不相关，即 $r(Y_1, Y_2) = 0$ 。则只需证 $Cov(Y_1, Y_2) = E(Y_1 Y_2) - EY_1 EY_2 = 0$ ，即 $E(Y_1 Y_2) = EY_1 EY_2$ 。

$$\begin{aligned}
E(Y_1 Y_2) &= E\left(\frac{X_1-\mu_1}{\sigma_1} \cdot \frac{1}{\sqrt{1-\rho^2}}\left(\frac{X_2-\mu_2}{\sigma_2}-\rho\frac{X_1-\mu_1}{\sigma_1}\right)\right) \\
&= \frac{1}{\sqrt{1-\rho^2}}\left(E\left(\frac{X_1-\mu_1}{\sigma_1} \cdot \frac{X_2-\mu_2}{\sigma_2} - \frac{X_1-\mu_1}{\sigma_1} \cdot \rho\frac{X_1-\mu_1}{\sigma_1}\right)\right),
\end{aligned}$$

由于 X_1 与 X_2 不相互独立，因而 $\frac{X_1-\mu_1}{\sigma_1}$ 与 $\frac{X_2-\mu_2}{\sigma_2}$ 也不相互独立，所以有

$$\begin{aligned}
E\left(\frac{X_1-\mu_1}{\sigma_1} \cdot \frac{X_2-\mu_2}{\sigma_2}\right) &= \text{cov}\left(\frac{X_1-\mu_1}{\sigma_1}, \frac{X_2-\mu_2}{\sigma_2}\right) - E\left(\frac{X_1-\mu_1}{\sigma_1}\right)E\left(\frac{X_2-\mu_2}{\sigma_2}\right) \\
&= \text{cov}\left(\frac{X_1-\mu_1}{\sigma_1}, \frac{X_2-\mu_2}{\sigma_2}\right) \\
&= \text{cov}\left(\frac{X_1}{\sigma_1} - \frac{\mu_1}{\sigma_1}, \frac{X_2}{\sigma_2} - \frac{\mu_2}{\sigma_2}\right) \\
&= \text{cov}\left(\frac{X_1}{\sigma_1}, \frac{X_2}{\sigma_2}\right), \\
&= \frac{1}{\sigma_1 \sigma_2} \text{cov}(X_1, X_2) \\
&= \frac{1}{\sigma_1 \sigma_2} \rho \sigma_1 \sigma_2 \\
&= \rho
\end{aligned}$$

又

$$\begin{aligned} E\left(\frac{X_1 - \mu_1}{\sigma_1} \cdot \rho \frac{X_1 - \mu_1}{\sigma_1}\right) &= \rho E\left(\left(\frac{X_1 - \mu_1}{\sigma_1}\right)^2\right) \\ &= \rho \left(D\left(\frac{X_1 - \mu_1}{\sigma_1}\right) + \left(E\left(\frac{X_1 - \mu_1}{\sigma_1}\right)\right)^2 \right), \\ &= \rho \end{aligned}$$

所以

$$\begin{aligned} E(Y_1 Y_2) &= \frac{1}{\sqrt{1-\rho^2}} \left(E\left(\frac{X_1 - \mu_1}{\sigma_1} \cdot \frac{X_2 - \mu_2}{\sigma_2} - \frac{X_1 - \mu_1}{\sigma_1} \cdot \rho \frac{X_1 - \mu_1}{\sigma_1}\right) \right) \\ &= \frac{1}{\sqrt{1-\rho^2}} (\rho - \rho) = 0 \end{aligned}$$

因而有 $E(Y_1 Y_2) = E Y_1 E Y_2$ ，所以 Y_1 与 Y_2 相互独立，从而 Y_1 与 Y_2 是相互独立的标准正态变量。

1.31 设 X_1, X_2, \dots, X_n 是来自 Weibull 分布的一个样本，其分布函数为：当 $x \leq 0$ 时 $F(x)=0$ ，当 $x > 0$ 时， $F(x)=1-\exp\{-(x/\eta)^m\}$ ，其中 $m > 0$ 为形状参数， $\eta > 0$ 为尺度参数，证明： $Y=\min(X_1, X_2, \dots, X_n)$ 仍服从 Weibull 分布。

解：设 $X_{(1)}, X_{(2)}, \dots, X_{(n)}$ 是 X_1, X_2, \dots, X_n 的次序统计量。

由题意可得： $X_1, X_2, \dots, X_n \sim \text{Weibull}(m, \eta)$ ，i.i.d.

$$\begin{aligned} P\{Y > y\} &= P\{\min(X_1, X_2, \dots, X_n) > y\} = P\{X_{(1)} > y\} \\ &= P\{X_1 > y, X_2 > y, \dots, X_n > y\} \\ &= P\{X_1 > y\} P\{X_2 > y\} \dots P\{X_n > y\} \\ &= [1-F(y)]^n \end{aligned}$$

其中，当 $y \leq 0$ 时 $F(y)=0$ ，当 $y > 0$ 时， $F(y)=P\{Y \leq y\}=1-\exp\{-(y/\eta)^m\}$ 。

因此，当 $y \leq 0$ 时， $P\{Y \leq y\}=P\{X_{(1)} \leq y\}=0$ ；

$$\begin{aligned} \text{当 } y > 0 \text{ 时, } P\{Y \leq y\} &= P\{X_{(1)} \leq y\} = 1 - P\{Y > y\} \\ &= 1 - [1-F(y)]^n \\ &= 1 - [1 - (1 - \exp\{-(y/\eta)^m\})]^n \\ &= 1 - [\exp\{-(y/\eta)^m\}]^n \\ &= 1 - \exp\{-(y/\eta)^{mn}\} \end{aligned}$$

综上， $Y=\min(X_1, X_2, \dots, X_n)$ 仍服从 Weibull 分布，即 $Y \sim \text{Weibull}(mn, \eta)$ 。

1.35

错误！未找到引用源。=错误！未找到引用源。 错误！未找到引用源。

错误！未找到引用源。期望方差的存在条件只需要错误！未找到引用源。的期望与方差存在即可。

由定理 1.2 可知，错误！未找到引用源。 , $i=k+1,k+2,\dots,n-k$.

错误！未找到引用源。 , 错误！未找到引用源。

错误！未找到引用源。

错误！未找到引用源。 ,错误！未找到引用源。

错误！未找到引用源。

错误！未找到引用源。 ,错误！未找到引用源。

1.36 设 X_1, \dots, X_n 是来自总体分布函数 $F(x)$ 的一个样本, $F_n(x)$ 为其经验分布函数

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n I_{|X_i \leq x|}$$

证明:

$$\sqrt{n}[F_n(x) - F(x)] \xrightarrow{L} N(0, F(x)[1 - F(x)])$$

证明:

令 $G_n = \sqrt{n}[F_n(x) - F(x)]$, 则

由 $E(I_{|X_i \leq x|}) = F(x)$, $E(I_{|X_i \leq x|})^2 = F(x)(1 - F(x))$, 得

$$\begin{aligned} E(G_n) &= E(\sqrt{n}[F_n(x) - F(x)]) \\ &= \sqrt{n}E([F_n(x) - F(x)]) = \sqrt{n}(E(F_n(x)) - E(F(x))) \\ &= \sqrt{n}\left(E\left(\frac{1}{n} \sum_{i=1}^n I_{|X_i \leq x|}\right) - F(x)\right) = \sqrt{n}\left(\frac{1}{n} \sum_{i=1}^n E(I_{|X_i \leq x|}) - F(x)\right) \\ &= \sqrt{n}(F(x) - F(x)) = 0 \end{aligned}$$

$$\begin{aligned}
\text{Var}(G_n) &= \text{Var}\left(\sqrt{n}\left[F_n(x) - F(x)\right]\right) \\
&= n\text{Var}\left[F_n(x) - F(x)\right] = n\text{Var}\left(\frac{1}{n}\sum_{i=1}^n I_{|X_i \leq x|}\right) \\
&= \frac{1}{n}\sum_{i=1}^n \text{Var}\left(I_{|X_i \leq x|}\right) = F(x)(1-F(x))
\end{aligned}$$

因此由中心极限定理可得

$$\sqrt{n}\left[F_n(x) - F(x)\right] \xrightarrow{L} N\left(0, F(x)[1-F(x)]\right)$$

1. 41. 设 X_1, \dots, X_n 是来自二点分布 $b(1, \theta)$ 的一个样本, 证明

$$T_k = (X_1 + \dots + X_k, X_{k+1}, \dots, X_n), k = 1, 2, \dots, n$$

都是 θ 的充分统计量。若对 T_k 给定 (t, t_{k+1}, \dots, t_n) , 请设计一个随机试验, 它能产生与原样本同分布的新样本。

解:

$$\begin{aligned}
p(X_1, X_2, \dots, X_n) &= \theta^{\sum_{i=1}^n x_i} (1-\theta)^{n-\sum_{i=1}^n x_i} \\
&= \left(\frac{\theta}{1-\theta}\right)^{\sum_{i=1}^n x_i} (1-\theta)^n \\
&= \left(\frac{\theta}{1-\theta}\right)^{\sum_{i=1}^n x_i} \left(\frac{\theta}{1-\theta}\right)^{x_{k+1}} \dots \left(\frac{\theta}{1-\theta}\right)^{x_n} (1-\theta)^n
\end{aligned}$$

则根据因子分解定理 $T_k = (X_1 + \dots + X_k, X_{k+1}, \dots, X_n)$ 是 θ 的充分统计量。

设计如下随机试验: 现有 $n-k+1$ 个位置进行试验, 第 1 个位置做 k 次试验, 其他位置 $(2, 3, \dots, n-k+1)$ 各做一次试验, 记录成功的次数, 这个随机试验产生的样本与原样本同分布。

1. 41 设 X_1, \dots, X_n 是来自二点分布 $b(1, \theta)$ 的一个样本, 证明

$$T_k = (X_1 + \dots + X_k, X_{k+1}, \dots, X_n), \quad k = 1, 2, \dots, n$$

都是 θ 的充分统计量. 若对 T_k 给定 (t, t_{k+1}, \dots, t_n) , 请设计一个随机试验, 它能产生与原样本同分布的新样本。

证明:

令 $W_k = X_1 + \cdots + X_k$, 显然 W_k 的分布为二项分布 $b(k, \theta)$, 即

$$P(W_k = t) = C_k^t \theta^t (1-\theta)^{k-t}$$

所以当 $T_k = (t, t_{k+1}, \cdots, t_n)$ 时, 样本的条件分布为

$$\begin{aligned} & P(X_1 = x_1, \cdots, X_n = x_n | T_k = (t, t_{k+1}, \cdots, t_n)) \\ &= \frac{P(X_1 = x_1, \cdots, X_n = x_n, T_k = (t, t_{k+1}, \cdots, t_n))}{P(T_k = (t, t_{k+1}, \cdots, t_n))} \\ &= \frac{P(X_{k+1} = t_{k+1}) \cdots P(X_n = t_n) P(X_1 = x_1, \cdots, X_k = x_k, W_k = t)}{P(T_k = (t, t_{k+1}, \cdots, t_n))} \\ &= \frac{\theta^t (1-\theta)^{k-t} \theta^{\sum_{i=k+1}^n t_i} (1-\theta)^{n-k-\sum_{i=k+1}^n t_i}}{C_k^t \theta^t (1-\theta)^{k-t} \theta^{\sum_{i=k+1}^n t_i} (1-\theta)^{n-k-\sum_{i=k+1}^n t_i}} = (C_k^t)^{-1} \end{aligned}$$

计算结果表明, 条件分布 $P(X = x | T_k = (t, t_{k+1}, \cdots, t_n))$ 对任意样本点 x 都不依赖于 θ , 所以 $T_k = (X_1 + \cdots + X_k, X_{k+1}, \cdots, X_n)$, $k = 1, 2, \cdots, n$ 都是 θ 的充分统计量.

42. 设 X_1, \cdots, X_n 是来自二项分布 $b(m, \theta)$ 的一个样本, 证明: $T_n = \sum_{i=1}^n X_i$ 是 θ 的充分统计量。

解: 该样本的联合分布列为:

$$p(X_1 = x_1, \cdots, X_n = x_n) = \frac{(m!)^n}{x_1! x_2! \cdots x_n! (m-x_1)! \cdots (m-x_n)!} \theta^{\sum_{i=1}^n x_i} (1-\theta)^{nm - \sum_{i=1}^n x_i}$$

取 $T(x) = \sum_{i=1}^n x_i$, $h(x) = \frac{(m!)^n}{x_1! x_2! \cdots x_n! (m-x_1)! \cdots (m-x_n)!}$, 则

$$p(X = x) = h(x) \cdot \theta^{T(x)} (1-\theta)^{nm - T(x)}$$

由因子分解定理知, $T(x) = \sum_{i=1}^n x_i$ 是 θ 的充分统计量。

1.42 设 X_1, \dots, X_n 是来自二项分布 $b(m, \theta)$ 的一个样本, 证明: $T_n = \sum_{i=1}^n X_i$ 是 θ

的充分统计量.

证明:

由题意得样本的联合分布列为

$$\begin{aligned} P(X_1 = x_1, \dots, X_n = x_n) &= C_m^{x_1} \theta^{x_1} (1-\theta)^{m-x_1} \dots C_m^{x_n} \theta^{x_n} (1-\theta)^{m-x_n} \\ &= \prod_{i=1}^n C_m^{x_i} \times \theta^{\sum_{i=1}^n x_i} (1-\theta)^{nm - \sum_{i=1}^n x_i} \end{aligned}$$

其中 $x_i = 0, 1, \dots, m$, $i = 1, \dots, n$

取 $T(x) = \sum_{i=1}^n X_i$, $h(x) = \prod_{i=1}^n C_m^{x_i}$, 就有

$$P_\theta(X_1 = x_1, \dots, X_n = x_n) = \theta^{T(x)} (1-\theta)^{nm-T(x)} h(x)$$

由因子分解定理可得, $T(x) = \sum_{i=1}^n X_i$ 是 θ 的充分统计量

1.51 设 $\begin{pmatrix} X_i \\ Y_i \end{pmatrix}$, $i=1, \dots, n$ 是来自正态分布族

$\left\{ N \left(\begin{pmatrix} \theta_1 \\ \theta_2 \end{pmatrix}, \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix} \right), -\infty < \theta_1, \theta_2 < +\infty, \sigma_1, \sigma_2 > 0, |\rho| \leq 1 \right\}$ 的一个二维

样本, 寻求该分布族的充分统计量。

解: 设 $X = (X_1, X_2)^T \sim N(\mu, \Sigma)$, 则 X 有概率密度

$$f(x) = \frac{1}{2\pi\sqrt{\det(\Sigma)}} \exp \left[-\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu) \right]$$

令 $A = \begin{pmatrix} X \\ Y \end{pmatrix}$, $\Sigma = \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}$, $U = \begin{pmatrix} \theta_1 \\ \theta_2 \end{pmatrix}$, 经计算

$$\Sigma^{-1} = \begin{pmatrix} \frac{1}{(1-\rho^2)\sigma_1^2} & \frac{\rho}{(\rho^2-1)\sigma_1\sigma_2} \\ \frac{\rho}{(\rho^2-1)\sigma_1\sigma_2} & \frac{1}{(1-\rho^2)\sigma_2^2} \end{pmatrix} \quad \text{令 } \Sigma^{-1} = \begin{pmatrix} a & b \\ b & d \end{pmatrix}$$

$$\text{则有 } (A-U)^T \Sigma^{-1} (A-U) = \begin{pmatrix} X - \theta_1 & Y - \theta_2 \end{pmatrix} \begin{pmatrix} a & b \\ b & d \end{pmatrix} \begin{pmatrix} X - \theta_1 \\ Y - \theta_2 \end{pmatrix}$$

$$= aX^2 - 2X(a\theta_1 - b\theta_2) + dY^2 - 2Y(b\theta_1 + d\theta_2) + 2bXY + a\theta_1^2 + 2b\theta_1\theta_2 +$$

$$\theta_2^2 d$$

$\begin{pmatrix} X_i \\ Y_i \end{pmatrix}$ 的联合密度函数为

$$P\left(\begin{pmatrix} X_i \\ Y_i \end{pmatrix}\right) = (2\pi)^{-n} |\Sigma|^{-\frac{n}{2}} \exp\left\{-\frac{1}{2} \Sigma^{-1} \sum_{i=1}^n (A_i - u)(A_i - u)^T\right\}$$

$$= (2\pi)^{-n} |\Sigma|^{-\frac{n}{2}}$$

$$\exp\left\{-\frac{1}{2} \left(a \sum_{i=1}^n X_i^2 - 2(a\theta_1 - b\theta_2) \sum_{i=1}^n X_i + d \sum_{i=1}^n Y_i^2 - 2(b\theta_1 + d\theta_2) \sum_{i=1}^n Y_i + 2b \sum_{i=1}^n X_i Y_i + (a\theta_1^2 + 2b\theta_1\theta_2 + d\theta_2^2) \right)\right\}$$

$$\text{令 } T_1 = \sum_{i=1}^n X_i^2, T_2 = \sum_{i=1}^n X_i, T_3 = \sum_{i=1}^n Y_i^2, T_4 = \sum_{i=1}^n Y_i, T_5 = \sum_{i=1}^n X_i Y_i$$

由因子分解定理知 $T = (T_1, T_2, T_3, T_4, T_5)$ 是它的充分统计量。

1.51 设 $\begin{pmatrix} X_i \\ Y_i \end{pmatrix}, i=1, \dots, n$ 是来自正态分布族

$$\left\{ N\left(\begin{pmatrix} \theta_1 \\ \theta_2 \end{pmatrix}, \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}\right), -\infty < \theta_1, \theta_2 < \infty, \sigma_1, \sigma_2 > 0, |\rho| \leq 1 \right\}$$

的一个二维样本，寻求该分布族的充分统计量。

解：

$$\text{令 } Z_i = \begin{pmatrix} X_i \\ Y_i \end{pmatrix}, \quad i=1, \dots, n, \quad \text{则}$$

$$P(z_i) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp \left\{ -\frac{1}{2(1-\rho^2)} \left[\frac{(x_1-\theta_1)^2}{\sigma_1^2} - 2\rho \frac{(x_1-\theta_1)(y_1-\theta_2)}{\sigma_1\sigma_2} + \frac{(y_1-\theta_2)^2}{\sigma_2^2} \right] \right\}$$

所以 (Z_1, Z_2, \dots, Z_n) 的联合密度函数为

$$\begin{aligned} P(z) &= \frac{1}{(2\pi)^n \sigma_1^n \sigma_2^n (1-\rho^2)^{n/2}} \exp \left\{ -\frac{1}{2(1-\rho^2)} \left[\sum_{i=1}^n \frac{(x_i-\theta_1)^2}{\sigma_1^2} - 2\rho \sum_{i=1}^n \frac{(x_i-\theta_1)(y_i-\theta_2)}{\sigma_1\sigma_2} + \sum_{i=1}^n \frac{(y_i-\theta_2)^2}{\sigma_2^2} \right] \right\} \\ &= \frac{1}{(2\pi)^n \sigma_1^n \sigma_2^n (1-\rho^2)^{n/2}} \exp \left\{ -\frac{1}{2(1-\rho^2)} \left[\frac{1}{\sigma_1^2} \left(\sum_{i=1}^n x_i^2 - 2\theta_1 \sum_{i=1}^n x_i + n\theta_1^2 \right) \right] \right\} \\ &\quad \times \exp \left\{ -\frac{1}{2(1-\rho^2)} \left[-\frac{2\rho}{\sigma_1\sigma_2} \left(\sum_{i=1}^n x_i y_i - \theta_1 \sum_{i=1}^n y_i - \theta_2 \sum_{i=1}^n x_i + n\theta_1\theta_2 \right) \right] \right\} \\ &\quad \times \exp \left\{ -\frac{1}{2(1-\rho^2)} \left[\frac{1}{\sigma_2^2} \left(\sum_{i=1}^n y_i^2 - 2\theta_2 \sum_{i=1}^n y_i + n\theta_2^2 \right) \right] \right\} \end{aligned}$$

故由因子分解定理可得，

$$\left(\sum_{i=1}^n x_i, \sum_{i=1}^n y_i, \sum_{i=1}^n x_i^2, \sum_{i=1}^n y_i^2, \sum_{i=1}^n x_i y_i \right) \text{ 是 } (\theta_1, \theta_2, \sigma_1^2, \sigma_2^2, \rho) \text{ 的充分统计量}$$

2.2 设 X_1, X_2 独立同分布，其共同密度函数为

$$\rho(x; \theta) = k\theta^k x^{-(k+1)}, x > \theta, \theta > 0, k > 2 \text{ 已知}$$

(1) 证明 $T_1 = \frac{k-1}{2k}(x_1 + x_2)$ 和 $T_2 = \frac{2k-1}{2k} \min(x_1, x_2)$ 都是 θ 的无偏估计；

(2) 计算 T_1 和 T_2 的均方误差并进行比较;

(3) 证明: 在均方误差意义下, 在形如 $T_c = c \min(x_1, x_2)$ 的估计中, $c = \frac{2k-2}{2k-1}$ 时最优。

解:

(1) 证明:

$$\begin{aligned} E(T_1) &= E\left(\frac{k-1}{2k}(x_1 + x_2)\right) = \frac{k-1}{2k} \cdot 2E(X) \\ &= \frac{k-1}{2k} \cdot 2 \int_{\theta}^{+\infty} x \rho(x; \theta) dx = \frac{k-1}{2k} \cdot 2 \int_{\theta}^{+\infty} x k \theta^k x^{-(k+1)} dx = \theta \end{aligned}$$

故 $T_1 = \frac{k-1}{2k}(x_1 + x_2)$ 是 θ 的无偏估计

$$E(T_2) = E\left(\frac{2k-1}{2k} \min(x_1, x_2)\right) = \frac{2k-1}{2k} E(X_{(1)}), \text{ 其中 } X_{(1)} = \min(x_1, x_2)$$

$X_{(1)}$ 的密度函数用 $\rho(y; \theta)$ 表示, 总体分布函数为

$$F(x; \theta) = \int_{-\infty}^x \rho(t; \theta) dt = \int_{\theta}^x k \theta^k x^{-(k+1)} dt = -\theta^k x^{-k} + 1$$

因此可得 $X_{(1)}$ 的密度函数为

$$\begin{aligned} \rho(y; \theta) &= 2[1 - F(y; \theta)] \rho(y; \theta) = 2[1 - (-\theta^k y^{-k} + 1)] k \theta^k y^{-(k+1)} \\ &= 2k \theta^{2k} y^{-2k-1} \end{aligned}$$

所以

$$\begin{aligned} E(T_2) &= \frac{2k-1}{2k} E(X_{(1)}) = \frac{2k-1}{2k} \int_{\theta}^{+\infty} y \rho(y; \theta) dy \\ &= \frac{2k-1}{2k} \int_{\theta}^{+\infty} y 2k \theta^{2k} y^{-2k-1} dy = \theta \end{aligned}$$

故 $T_2 = \frac{2k-1}{2k} \min(x_1, x_2)$ 是 θ 的无偏估计

(2) 因为 $T_i (i=1, 2)$ 都是 θ 的无偏估计, 所以均方误差为

$$MSE_{\theta}(T_i) = \text{Var}(T_i) (i=1, 2)$$

因此

$$MSE_{\theta}(T_1) = VarT_1 = Var\left(\frac{k-1}{2k}(x_1 + x_2)\right) = \left(\frac{k-1}{2k}\right)^2 \cdot 2VarX_1 \quad (1)$$

$$\begin{aligned} VarX_1 &= EX_1^2 - (EX_1)^2 = \int_{\theta}^{+\infty} x^2 \rho(x; \theta) dx - \left(\int_{\theta}^{+\infty} x \rho(x; \theta) dx\right)^2 \\ &= \int_{\theta}^{+\infty} x^2 k \theta^k x^{-(k+1)} dx - \left(\int_{\theta}^{+\infty} x k \theta^k x^{-(k+1)} dx\right)^2 \\ &= \frac{k}{k-2} \theta^2 - \left(\frac{k}{k-1} \theta\right)^2 = \frac{k}{(k-1)^2 (k-2)} \theta^2 \end{aligned} \quad (2)$$

$$\text{将 (2) 式代入 (1) 式得到 } MSE_{\theta}(T_1) = \frac{\theta^2}{2k(k-2)} \quad (5)$$

同理可得

$$MSE_{\theta}(T_2) = VarT_2 = Var\left(\frac{2k-1}{2k} \min(x_1, x_2)\right) = \left(\frac{2k-1}{2k}\right)^2 VarX_{(1)} \quad (3)$$

$$\begin{aligned} VarX_{(1)} &= EX_{(1)}^2 - (EX_{(1)})^2 = \int_{\theta}^{+\infty} y^2 \rho(y; \theta) dy - \left(\int_{\theta}^{+\infty} y \rho(y; \theta) dy\right)^2 \\ &= \int_{\theta}^{+\infty} y^2 2k \theta^{2k} y^{-2k-1} dy - \left(\int_{\theta}^{+\infty} y k \theta^k y^{-(k+1)} dy\right)^2 \\ &= \frac{2k}{2k-2} \theta^2 - \left(\frac{2k}{2k-1} \theta\right)^2 = \frac{k}{(k-1)(2k-1)^2} \theta^2 \end{aligned} \quad (4)$$

$$\text{将 (4) 式代入 (3) 式得 } MSE_{\theta}(T_2) = \frac{\theta^2}{4k(k-1)} \quad (6)$$

比较 (5) 式和 (6) 式可得

$$MSE_{\theta}(T_2) < MSE_{\theta}(T_1)$$

(3) 由均方误差的定义可得

$$MSE_{\theta}(T_c) = VarT_c + (ET_c - \theta)^2 \quad (7)$$

$$VarT_c = Var(c \min(x_1, x_2)) = c^2 VarX_{(1)} \quad (8)$$

$$\text{将 (4) 式代入 (8) 式得 } VarT_c = c^2 \frac{k}{(k-1)(2k-1)^2} \theta^2 \quad (9)$$

$$ET_c = E(c \min(x_1, x_2)) = cEX_{(1)} = c \int_{\theta}^{+\infty} yk\theta^k y^{-(k+1)} dy = c \frac{2k}{2k-1} \theta \quad (10)$$

将 (9)、(10) 式代入 (7) 式得

$$\begin{aligned} MSE_{\theta}(T_c) &= c^2 \frac{k}{(k-1)(2k-1)^2} \theta^2 + \left(c \frac{2k}{2k-1} \theta - \theta \right)^2 \\ &= \frac{(4k^3 - 4k^2 + k)c^2 + (-8k^3 + 16k^2 - 8k)c + 4k^3 - 8k^2 + 5k - 1}{(k-1)(2k-1)^2} \theta^2 \end{aligned}$$

因为 $4k^3 - 4k^2 + k > 0$ ，所以 $MSE_{\theta}(T_c)$ 可达到最小值，此时 $c = \left(\frac{2k-2}{2k-1} \right)^2$

2.3

(1)证明:

由于密度函数为 $p(x; \theta) = k\theta^k x^{-(k+1)}$ ，

所以可求得:

$$E(X) = \int_{\theta}^{\infty} xp(x; \theta)dx = \frac{k}{(k-1)} \theta$$

$$E(X^2) = \int_{\theta}^{\infty} x^2 p(x; \theta)dx = \frac{k}{(k-2)} \theta^2$$

$$\text{Var}(X) = E(X^2) - (E(X))^2 = \frac{k}{(k-2)(k-1)^2} \theta^2$$

因为

$$T_1 = \frac{k}{k-1} \frac{x_1 + x_2}{2}$$

则

$$E(T_1) = \frac{k-1}{k} E\left(\frac{x_1 + x_2}{2}\right) = \theta$$

由于 T_2 为次序统计量，则 T_2 的密度函数为

$$g(y; \theta) = (2k-1)\theta^{2k} y^{-(2k+1)}$$

因此

$$E(T_2) = \int_{\theta}^{\infty} yg(y; \theta)dy = \theta$$

故得证。

(2) 由于 T_1, T_2 为无偏估计,

所以

$$MSE_{\theta}(T_i) = \text{Var}(T_i) \quad i = 1, 2$$

可求得

$$\text{Var}(T_1) = \text{Var}\left(\frac{k-1}{k} \frac{x_1 + x_2}{2}\right) = \frac{(k-1)^2}{k^2} \frac{\text{Var}X}{4} = \frac{\theta^2}{4k(k-2)}$$

$$\text{Var}(T_2) = E(T_2^2) - (E(T_2))^2 = \frac{2(k-1)}{2(k-2)} \theta^2 - \theta^2 = \frac{\theta^2}{2(k-1)}$$

(3)

证明:

对于 θ 的估计 $\hat{\theta}$, $a > 0$ 为常数,

考虑:

$$MSE_{\theta}(a\hat{\theta}) = E(a\hat{\theta} - \theta)^2 = a^2 E(\hat{\theta} - \theta)^2 + (1 - a^2)\theta^2$$

由简单求导可得

$$a = \theta^2 / (\theta^2 + \text{Var} \hat{\theta})$$

均方误差最小,

由上题可知

$$\text{Var}(T_2) = E(T_2^2) - (E(T_2))^2 = \frac{2(k-1)}{2(k-2)} \theta^2 - \theta^2 = \frac{\theta^2}{2(k-1)}$$

代入上式可求

$$a = \frac{2k-2}{2k-1}$$

得证。

2.3 设 $\theta \in (a, b)$, $T(X)$ 是 θ 的无偏估计, 令

$$S(x) = \begin{cases} T(x), & a \leq T(x) \leq b \\ a, & T(x) < a \\ b, & T(x) > b \end{cases}$$

证明: $E(S(x) - \theta)^2 \leq E(T(x) - \theta)^2$.

证明:

(1) 当 $a \leq T(x) \leq b$ 时, $S(x) = T(x)$. 结论显然成立

(2) 当 $T(x) < a$ 时,

$$\begin{aligned} E(S(x) - \theta)^2 &= E(S(x) - E(S(x)) + E(S(x)) - \theta)^2 = E\left(S(x) - E(S(x))\right)^2 + (E(S(x)) - \theta)^2 \\ &= (a - \theta)^2 \end{aligned}$$

$$\begin{aligned} E(T(x) - \theta)^2 &= E(T(x) - E(T(x)) + E(T(x)) - \theta)^2 = E\left(T(x) - E(T(x))\right)^2 + (E(T(x)) - \theta)^2 \\ &= E(T(x) - \theta)^2 = \int (T(x) - \theta)^2 p(x) dx \geq \int (a - \theta)^2 p(x) dx \\ &= (a - \theta)^2 \int p(x) dx = (a - \theta)^2 \end{aligned}$$

(3) 当 $T(x) > b$ 时,

$$\begin{aligned} E(S(x) - \theta)^2 &= E(S(x) - E(S(x)) + E(S(x)) - \theta)^2 = E\left(S(x) - E(S(x))\right)^2 + (E(S(x)) - \theta)^2 \\ &= (b - \theta)^2 \end{aligned}$$

$$\begin{aligned} E(T(x) - \theta)^2 &= E(T(x) - E(T(x)) + E(T(x)) - \theta)^2 = E\left(T(x) - E(T(x))\right)^2 + (E(T(x)) - \theta)^2 \\ &= E(T(x) - \theta)^2 = \int (T(x) - \theta)^2 p(x) dx \geq \int (b - \theta)^2 p(x) dx \\ &= (b - \theta)^2 \int p(x) dx = (b - \theta)^2 \end{aligned}$$

综上, 结论得证。

2.6

解: 对任意的 ε , 由切比雪夫不等式, 有

$$P\left(\left|\hat{\theta}_n - E\hat{\theta}_n\right| \geq \frac{\varepsilon}{2}\right) \leq \frac{4}{\varepsilon^2} \text{Var}(\hat{\theta}_n)$$

由题意,

$$E\hat{\theta}_n \rightarrow \theta, \text{ 对任意的 } \varepsilon, \text{ 当充分大时, 有 } |E\hat{\theta}_n - \theta| < \frac{\varepsilon}{2}$$

$$|\hat{\theta}_n - \theta| \leq |\hat{\theta}_n - E\hat{\theta}_n| + |E\hat{\theta}_n - \theta|$$

$$\text{若 } |\hat{\theta}_n - E\hat{\theta}_n| < \frac{\varepsilon}{2}, \text{ 有 } |\hat{\theta}_n - \theta| < \varepsilon$$

$$\text{若 } |\hat{\theta}_n - \theta| \geq \varepsilon, \text{ 则 } |\hat{\theta}_n - E\hat{\theta}_n| \geq \frac{\varepsilon}{2}$$

$$\{|\hat{\theta}_n - \theta| \geq \varepsilon\} \subset \left\{|\hat{\theta}_n - E\hat{\theta}_n| \geq \frac{\varepsilon}{2}\right\}, \text{ 故}$$

$$P(|\hat{\theta}_n - \theta| \geq \varepsilon) \leq P\left(|\hat{\theta}_n - E\hat{\theta}_n| \geq \frac{\varepsilon}{2}\right) \leq \frac{4}{\varepsilon^2} \text{Var}(\hat{\theta}_n) \rightarrow 0$$

(当 $n \rightarrow \infty$)

2.7

证明:

由题意,

$$E(\hat{\mu}) = \frac{2}{n(n+1)} \left(\sum_{i=1}^n i E(X_i) \right) = \frac{2}{n(n+1)} \frac{(1+n)n}{2} E(X_1) = \mu$$

$$\begin{aligned} \therefore \text{Var}(\hat{\mu}) &= \frac{4}{n^2(n+1)^2} \left(\sum_{i=1}^n i^2 \text{Var}(X_i) \right) = \frac{4}{n^2(n+1)^2} \frac{n(n+1)(2n+1)}{6} \text{Var}(X_1) \\ &= \frac{4(2n+1)}{6n(n+1)} \text{Var}(X_1) \end{aligned}$$

由上题结论, 得证

2.7

证明: 错误! 未找到引用源。是 μ 的相合估计, 即证错误! 未找到引用源。

记错误! 未找到引用源。 , 则有 $E(\text{错误! 未找到引用源。}) = \mu$, $\text{Var}(\text{错误! 未找到引用源。}) = \text{错误! 未找到引用源。}$

由切比雪夫定理可知, 对任意 $\varepsilon > 0$, 有

$$P\{|\mu_n - \mu| \geq \varepsilon\} \leq \frac{\text{Var}\mu_n}{\varepsilon^2}$$

令 n 趋于无穷时, 错误! 未找到引用源。趋于 0, 所以错误! 未找到引用源。是 μ 的相合估计。

2.8 设 X_1, \dots, X_n 是来自 $U(0, n\lambda)$ 的一个样本,

(1) 证明 $n\lambda - X_{(n)}$ 的分布收敛于 $\text{Exp}(\frac{1}{\lambda})$;

(2) 用 (1) 中结果给出 λ 的一个相合估计。

(1) 证明：由次序统计量 $X_{(n)}$ 的密度函数公式可得

$$p(X_{(n)}) = n \cdot \left(\frac{x}{n\lambda}\right)^{n-1} \cdot \frac{1}{n\lambda} = n \cdot \frac{x^{n-1}}{(n\lambda)^n}$$

令 $Y = n\lambda - X_{(n)}$ ，则 $F_Y(y) = P(Y \leq y) = P(n\lambda - X_{(n)} \leq y) = P(X_{(n)} \geq n\lambda - y)$

$$= 1 - P(X_{(n)} < n\lambda - y) = 1 - \int_0^{n\lambda-y} \frac{nx^{n-1}}{(n\lambda)^n} dx$$

$$= \begin{cases} 1 - \left(\frac{n\lambda - y}{n\lambda}\right)^n, & y \geq 0 \\ 0, & y < 0 \end{cases}$$

当 $y \geq 0$ 时， $\lim_{n \rightarrow \infty} F_Y(y) = \lim_{n \rightarrow \infty} 1 - \left(1 - \frac{y}{n\lambda}\right)^n = \lim_{n \rightarrow \infty} 1 - \left[\left(1 - \frac{y}{n\lambda}\right)^{\frac{n\lambda}{y}}\right]^{\frac{y}{\lambda}} = 1 - e^{-\frac{y}{\lambda}}$

$\text{Exp}\left(\frac{1}{\lambda}\right)$ 的分布函数为 $F(x) = \begin{cases} 1 - e^{-\frac{x}{\lambda}}, & x \geq 0 \\ 0, & x < 0 \end{cases}$

$\therefore n\lambda - X_{(n)} \xrightarrow{L} \text{Exp}\left(\frac{1}{\lambda}\right)$

$$\begin{aligned} (2) \quad \forall \varepsilon > 0, P\left(\left|\frac{X_{(n)}}{n} - \lambda\right| \geq \varepsilon\right) &= P(X_{(n)} \leq n\lambda - n\varepsilon) = \int_0^{n\lambda-n\varepsilon} \frac{nx^{n-1}}{(n\lambda)^n} dx = \left(\frac{n\lambda - n\varepsilon}{n\lambda}\right)^n \\ &= \left(\frac{\lambda - \varepsilon}{\lambda}\right)^n \rightarrow 0 (n \rightarrow \infty) \end{aligned}$$

$\therefore \frac{X_{(n)}}{n}$ 是 λ 的一个相合估计。

2.9 设 $(X_1, Y_1), \dots, (X_n, Y_n)$ 为独立同分布的二元正态变量，

$EX_1 = EY_1 = 0$, $\text{Var}X_1 = \text{Var}Y_1 = 1$, $\text{Cov}(X_1, Y_1) = \rho$ 。记

$$S_{xx} = \frac{1}{n} \sum X_i^2, \quad S_{xy} = \frac{1}{n} \sum X_i Y_i, \quad S_{yy} = \frac{1}{n} \sum Y_i^2$$

(1) 证明 $\sqrt{n}(S_{xx} - 1, S_{xy} - \rho, S_{yy} - 1) \xrightarrow{L} N_3(0, \Sigma)$ ，其中

$$\Sigma = \begin{pmatrix} 2 & 2\rho & 2\rho^2 \\ 2\rho & 1 + \rho^2 & 2\rho \\ 2\rho^2 & 2\rho & 2 \end{pmatrix}$$

(2) 令 $r = S_{xy} / \sqrt{S_{xx} S_{yy}}$ ，求 $\sqrt{n}(r - \rho)$ 的渐近分布。

证明：(1) 因为 (X_i, Y_i) 服从二元正态分布且

$$EX_1 = EY_1 = 0, \text{Var}X_1 = \text{Var}Y_1 = 1, \text{Cov}(X_1, Y_1) = \rho. \text{ 所以 } X_i \sim N(0, 1), Y_i \sim N(0, 1),$$

$$E(X_i^2) = 1, E(Y_i^2) = 1. \text{ 又因为 } (X_i, Y_i) \text{ 之间是相互独立的, 所以 } \sum X_i^2 \sim \chi^2(n),$$

$$\sum Y_i^2 \sim \chi^2(n).$$

$$E(S_{xx}) = E\left(\frac{1}{n} \sum X_i^2\right) = \frac{1}{n} \cdot n = 1, \quad E(S_{yy}) = E\left(\frac{1}{n} \sum Y_i^2\right) = \frac{1}{n} \cdot n = 1.$$

又因为 $\text{Cov}(X_i, Y_i) = E(X_i Y_i) - EX_i EY_i = \rho$, 所以 $E(X_i Y_i) = \rho$, 从而

$$E(S_{xy}) = \frac{n\rho}{n} = \rho.$$

$$\text{令 } Z = \sqrt{n}(S_{xx} - 1, S_{xy} - \rho, S_{yy} - 1)^T, \text{ 所以 } E(Z) = (0, 0, 0)^T.$$

$$\text{Var}(S_{xx}) = \text{Var}\left(\frac{1}{n} \sum X_i^2\right) = \frac{1}{n^2} \text{Var}\left(\sum X_i^2\right) = \frac{2n}{n^2} = \frac{2}{n},$$

$$\text{Var}(S_{yy}) = \text{Var}\left(\frac{1}{n} \sum Y_i^2\right) = \frac{1}{n^2} \text{Var}\left(\sum Y_i^2\right) = \frac{2n}{n^2} = \frac{2}{n},$$

$$\begin{aligned} \text{Var}(S_{xy}) &= E\left[\frac{1}{n^2} \left(\sum X_i Y_i\right)^2\right] - \left[E\left(\frac{1}{n} \sum X_i Y_i\right)\right]^2 \\ &= \frac{1}{n^2} E\left(\sum X_i Y_i\right)^2 - \left[\frac{1}{n} n E(X_i Y_i)\right]^2 \\ &= \frac{1}{n^2} E\left(\sum X_i^2 Y_i^2 + 2 \sum_{i \neq j} X_i Y_i X_j Y_j\right) - [E(X_i Y_i)]^2 \\ &= \frac{1}{n^2} [n E(X_i^2 Y_i^2) + n(n-1) E(X_i Y_i) E(X_j Y_j)] - \rho^2 \\ &= \frac{1}{n} E(X_i^2 Y_i^2) + \frac{n-1}{n} \rho^2 - \rho^2 \\ &= \frac{1}{n} E(X_i^2 Y_i^2) - \frac{\rho^2}{n} \end{aligned}$$

因为 $X_i | Y_i \sim N\left(\mu_1 + \rho \frac{\sigma_1}{\sigma_2} (y - \mu_2), (1 - \rho^2) \sigma_1^2\right)$, 所以 $X_i | Y_i \sim N(\rho y, (1 - \rho^2))$ 。

所以 $E(X_i^2 | Y_i) = [E(X_i | Y_i)]^2 + \text{Var}(X_i | Y_i) = \rho^2 y^2 + 1 - \rho^2$, 所以

$$\begin{aligned} E(X_i^2 Y_i^2) &= E[E(X_i^2 Y_i^2 | Y_i)] = E[Y_i^2 E(X_i^2 | Y_i)] = E[Y_i^2 (\rho^2 Y_i^2 + 1 - \rho^2)] \\ &= E[\rho^2 Y_i^4 + (1 - \rho^2) Y_i^2] = \rho^2 E(Y_i^4) + (1 - \rho^2) \end{aligned}$$

又因为 $E(Y_i^4) = E(Y_i^2)^2 + \text{Var}(Y_i^2) = 1 + 2 = 3$ ，所以

$$E(X_i^2 Y_i^2) = 3\rho^2 + (1 - \rho^2) = 1 + 2\rho^2$$

$$\text{所以 } \text{Var}(S_{xy}) = \frac{1 + 2\rho^2}{n} - \frac{\rho^2}{n} = \frac{1 + \rho^2}{n}。$$

$$\begin{aligned} \text{Cov}(S_{xx}, S_{yy}) &= \text{Cov}\left(\frac{1}{n} \sum X_i^2, \frac{1}{n} \sum Y_i^2\right) = \frac{1}{n^2} \text{Cov}\left(\sum X_i^2, \sum Y_i^2\right) = \frac{1}{n} \text{Cov}(X_i^2, Y_i^2) \\ &= \frac{1}{n} [E(X_i^2 Y_i^2) - EX_i^2 EY_i^2] = \frac{1}{n} (1 + 2\rho^2 - 1) = \frac{2\rho^2}{n} \end{aligned}$$

$$\begin{aligned} \text{Cov}(S_{xx}, S_{xy}) &= \text{Cov}\left(\frac{1}{n} \sum X_i^2, \frac{1}{n} \sum X_i Y_i\right) = \frac{1}{n^2} \text{Cov}\left(\sum X_i^2, \sum X_i Y_i\right) = \frac{1}{n} \text{Cov}(X_i^2, X_i Y_i) \\ &= \frac{1}{n} [E(X_i^3 Y_i) - E(X_i^2) E(X_i Y_i)] \end{aligned}$$

因为 $Y_i | X_i \sim N(\rho X_i, (1 - \rho^2))$ ，所以

$$\begin{aligned} E(X_i^3 Y_i) &= E[E(X_i^3 Y_i | X_i)] = E[X_i^3 E(Y_i | X_i)] = E(X_i^3 \rho X_i) \\ &= \rho E(X_i^4) = \rho [E(X_i^2)^2 + \text{Var}(X_i^2)] = 3\rho \end{aligned}$$

$$\text{所以 } \text{Cov}(S_{xx}, S_{xy}) = \frac{1}{n} (3\rho - \rho) = \frac{2\rho}{n}。$$

同理可得 $\text{Cov}(S_{yy}, S_{xy}) = \frac{2\rho}{n}$ ，所以

$$\text{Var}(Z) = \text{Var}[\sqrt{n}(S_{xx} - 1), \sqrt{n}(S_{xy} - \rho), \sqrt{n}(S_{yy} - 1)] = \Sigma$$

由中心极限定理可知： $\sqrt{n}(S_{xx} - 1, S_{xy} - \rho, S_{yy} - 1) \xrightarrow{L} N_3(0, \Sigma)。$

(2) 令 $T = (S_{xx}, S_{xy}, S_{yy})^T$ ， $\theta = (1, \rho, 1)^T$ ，由 (1) 可得

$$\sqrt{n}(T - \theta)^T \xrightarrow{L} N_3(0, \Sigma)$$

因为 $r = S_{xy} / \sqrt{S_{xx} S_{yy}}$ ，所以 设 $g(x, y, z) = \frac{y}{\sqrt{xz}}$ ，所以

$$\frac{\partial g}{\partial x} = \frac{-y}{2x\sqrt{xz}}, \quad \frac{\partial g}{\partial y} = \frac{-1}{\sqrt{xz}}, \quad \frac{\partial g}{\partial z} = \frac{-y}{2z\sqrt{xz}}$$

$$\text{记 } \Delta = \left(\frac{\partial g}{\partial x}, \frac{\partial g}{\partial y}, \frac{\partial g}{\partial z} \right)^T \bigg|_{(x,y,z)=(1,\rho,1)} = \left(-\frac{\rho}{2}, 1, -\frac{\rho}{2} \right)^T,$$

又因为 $\sqrt{n}(T - \theta)^T \xrightarrow{L} N_3(0, \Sigma)$, 所以 $\sqrt{n}(g(T) - g(\theta)) \xrightarrow{L} N_3(0, \Sigma')$, 其中

$$\Sigma' = \Delta^T \Sigma \Delta.$$

$$\Sigma' = \begin{pmatrix} -\frac{\rho}{2} & 1 & -\frac{\rho}{2} \end{pmatrix} \begin{pmatrix} 2 & 2\rho & 2\rho^2 \\ 2\rho & 1+\rho^2 & 2\rho \\ 2\rho^2 & 2\rho & 2 \end{pmatrix} \begin{pmatrix} -\frac{\rho}{2} \\ 1 \\ -\frac{\rho}{2} \end{pmatrix} = (1-\rho^2)^2$$

所以 $\sqrt{n}(g(T) - g(\theta))^T \xrightarrow{L} N_3(0, (1-\rho^2)^2)$, 即 $\sqrt{n}(r - \rho) \xrightarrow{L} N_3(0, (1-\rho^2)^2)$ 。

2.12

(1) 证明: 若 $\phi(x)$ 满足 $E_\theta \phi(x) = 0$, 即 $\sum_{x=1}^{\theta} \frac{\phi(x)}{\theta} = 0$ 对 $\forall \theta = 1, 2, \dots$ 恒成立, 则

当 $\theta=1$ 时, $\phi(1)=0$,

当 $\theta=2$ 时, $\frac{1}{2}(\phi(1) + \phi(2)) = 0$, 即 $\phi(2)=0$,

...

则当 $x=1, 2, \dots$ 时, $\phi(x)=0$, 即 $\phi(x)=0, a.s. P_\theta$, 故 \wp 是完备的。

(2) 由题意, $P_\theta(X=i) = \frac{1}{\theta} \cdot I_{(X=1, 2, \dots, \theta)} = g_\theta(T) \cdot h(X)$, 其中 $T = X, h(X)=1$, 故 X 是 θ 的充分统计量, 又 \wp 是完备的, 且 $E X = \sum_{i=1}^{\theta} i/\theta = \frac{1+\theta}{2}$, 故 $2X-1$ 是 θ 的 UMVUE。

(3) 假设 \wp_k 完备, 由(1)的过程, 可知当 $x < k$ 时, $\phi(x)=0$, 现在对于 $\phi(x)$, 当 $x=k$ 时, 令 $\phi(x)=1$, 当 $x=k+1$ 时, 令 $\phi(x)=-1$, 当 $x > k+1$ 时, 令 $\phi(x)=0$, 即此时找到一个函数 $\phi(x)$ 满足 $E_\theta \phi(x)=0$ 时, $\phi(x)$ 不是几乎处处为零, 即 \wp_k 是不完备的。

(4) 不妨设 $\theta^* = \hat{\theta} + \phi(x)$, $\phi(x)$ 满足(3)中的条件, 且 $E \theta^* = E \hat{\theta} = \theta$, 则 $\text{Var}(\theta^*) = E(\theta^* - \hat{\theta} + \hat{\theta} - \theta)^2 = E(\theta^* - \hat{\theta})^2$

$$+ 2E(\theta^* - \hat{\theta})(\hat{\theta} - \theta) + \text{Var}(\hat{\theta}) = \frac{1}{\theta} \left[\sum_{i=1}^{\theta} \phi^2(i) + 2\phi(i)(2i-1-\theta) \right] + \text{Var}(\hat{\theta}) = \text{Var}(\hat{\theta}) - \frac{2}{\theta} < \text{Var}(\hat{\theta}),$$

故对 \wp_k , $\hat{\theta}$ 不是 θ 的 UMVUE。

2.13

考虑幂级数分布的参数估计问题，设 X_1, \dots, X_n 是来自

$$\Pr(X = x) = \frac{a_x}{f(\theta)} \theta^x, \quad x = c, c+1, \dots, \infty \quad (2.73)$$

的一个样本，令 $T = \sum_{i=1}^n X_i$

(1) 证明： T 是 θ 的完备充分统计量，且 T 的分布仍具 (2.73) 形式

$$\Pr(T = t) = \frac{b_t}{f^n(\theta)} \theta^t, \quad t = nc, nc+1, \dots, \infty$$

(2) 证明 θ^r 的 UMVUE 是

$$\hat{\theta}^r = \begin{cases} 0, & t < r + nc \\ b_{t-r} / b_t, & t \geq r + nc \end{cases}$$

(3) 证明：若 X 的取值范围有限，则 (1), (2) 中的结论不再正确。

$$\begin{aligned} \text{证明: (1) } \Pr(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n) &= \frac{a_{x_1} \cdot a_{x_2} \cdot \dots \cdot a_{x_n}}{[f(\theta)]^n} \theta^{x_1 + x_2 + \dots + x_n} \\ &= \frac{a_{x_1} \cdot a_{x_2} \cdot \dots \cdot a_{x_n}}{[f(\theta)]^n} \theta^t \end{aligned}$$

$$\text{令 } h(x) = a_{x_1} \cdot a_{x_2} \cdot \dots \cdot a_{x_n}, \quad g(\theta, T(x)) = \frac{\theta^t}{(f(\theta))^n}$$

所以 T 是 θ 的充分统计量

$$\Pr(X_1 = x_1, X_2 = x_2, \dots, X_{n-1} = x_{n-1}, T = t) = \frac{a_{x_1} \cdot a_{x_2} \cdot \dots \cdot a_{x_{n-1}} \cdot a_{t-x_1-\dots-x_{n-1}}}{[f(\theta)]^n} \theta^t$$

$$\Pr(T = t) = (x_1 + x_2 + \dots + x_{n-1}) \frac{a_{x_1} \cdot a_{x_2} \cdot \dots \cdot a_{x_{n-1}} \cdot a_{t-x_1-\dots-x_{n-1}}}{[f(\theta)]^n} \theta^t$$

$$= \frac{b_t}{[f(\theta)]^n} \theta^t, \quad t = nc, nc+1, \dots, \infty$$

$$\Pr(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n) = \frac{a_{x_1} \cdot a_{x_2} \cdot \dots \cdot a_{x_n}}{[f(\theta)]^n} \theta^{x_1 + x_2 + \dots + x_n}$$

$$= \frac{a_{x_1} \cdot a_{x_2} \cdot \dots \cdot a_{x_n}}{[f(e^{\ln \theta})]^n} e^{(x_1 + x_2 + \dots + x_n) \ln \theta}$$

所以 T 是 θ 的完备统计量

所以 T 是 θ 的完备充分统计量

$$\begin{aligned} (2) \quad E(\hat{\theta}^r) &= E\left(\frac{b_{t-r}}{b_t}\right) \\ &= \sum_{t=nc+r}^{\infty} \Pr(T=t) \\ &= \sum_{t=nc+r}^{\infty} \frac{b_{t-r}}{b_t} \cdot \frac{b_t}{[f(\theta)]^n} \cdot \theta^t \\ &\stackrel{m=t-r}{=} \sum_{m=t-r}^{\infty} \frac{b_m}{[f(\theta)]^n} \cdot \theta^m \cdot \theta^r \\ &= \theta^r \end{aligned}$$

所以 $\hat{\theta}^r$ 是 θ^r 的 UMVUE

(3)

先说明 (1) 不成立

$$\Pr(X=x) = \frac{a_x}{f(\theta)} \theta^x, \quad x=c, c+1, \dots, k (k \geq c)$$

$$\Pr(T=t) = \frac{b_t}{[f(\theta)]^n} \theta^t, \quad t=nc, nc+1, \dots, nk (k \geq c)$$

$$\begin{aligned} E(\varphi(t)) &= \sum_{t=nc}^{nk} \varphi(t) \Pr(T=t) \\ &= \sum_{t=nc}^{nk} \varphi(t) \frac{b_t}{[f(\theta)]^n} \theta^t \end{aligned}$$

令上式只有有限项且值为 0，且令 $\varphi(t) \neq 0$ ，所以可以推出 (1) 不成立

再说明 (2) 不成立

若 $\hat{\theta}^r$ 是 θ^r 的 UMVUE

$$E(\hat{\theta}^r) = \sum_{t=nc+r}^{nk} \frac{b_{t-r}}{b_t} \cdot \frac{b_t}{[f(\theta)]^n} \theta^t$$

$$= \theta^r$$

$$\sum_{t=nc+r}^{nk} \theta^{t-r} \cdot \frac{b_t}{[f(\theta)]^n} \theta^r = \theta^r$$

$$\text{所以有 } \sum_{t=nc+r}^{nk} \theta^{t-r} \cdot \frac{b_{t-r}}{[f(\theta)]^n} \theta^{t-r} = 1$$

$$\text{又因为 } \sum_{t=nc}^{nk} \Pr(T=t) = 1$$

$$\text{所以有 } \sum_{t=nc+r}^{nk+r} \theta^{t-r} \cdot \frac{b_{t-r}}{[f(\theta)]^n} \theta^{t-r} = 1$$

$$\sum_{t=nc+r}^{nk} \theta^{t-r} \cdot \frac{b_{t-r}}{[f(\theta)]^n} \theta^{t-r} = 1 < \sum_{t=nc+r}^{nk+r} \theta^{t-r} \cdot \frac{b_{t-r}}{[f(\theta)]^n} \theta^{t-r} = 1$$

矛盾，所以（2）不成立

所以当 x 的取值范围有限，则（1），（2）中的结论不再成立

2.14 设 X_1, X_2, \dots, X_n 是来自 $N(q, 1)$ 的一个样本，令 $g(q) = \Pr(X_1 \leq 0)$ ，试求 $g(q)$ 的 UMVUE.

解：由 $X_1, X_2, \dots, X_n \sim N(\theta, 1)$ ，则：

$$P(x_1, x_2, \dots, x_n) = \frac{1}{(2\pi)^{\frac{n}{2}}} \exp \left\{ -\frac{1}{2} \sum_{i=1}^n (x_i - \theta)^2 \right\}$$

$$P(x_1, x_2, \dots, x_n) = \frac{1}{(2\pi)^{\frac{n}{2}}} \exp \left\{ -\frac{1}{2} \sum_{i=1}^n (\theta^2 - 2\theta x_i) \right\} \exp \left\{ -\frac{1}{2} \sum_{i=1}^n x_i^2 \right\}$$

$$= h_\theta(T) h(x)$$

其中 $T = \frac{1}{n} \sum_{i=1}^n x_i$ ，则 T 为充分统计量，且 $T \sim N(\theta, \frac{1}{n})$ ，易证 T 为完备统计量

$$\text{另一方面：} \quad g(\theta) = \Pr(X_1 \leq 0) = \int_{-\infty}^0 \frac{1}{\sqrt{2\pi}} \exp \left\{ -\frac{1}{2} (x_1 - \theta)^2 \right\} dx_1$$

$$= \int_{-\infty}^{-\theta} \frac{1}{\sqrt{2\pi}} \exp\left\{-\frac{1}{2}y^2\right\} dy = \Phi(-\theta) \quad (\text{令 } y=x_1-\theta)$$

取 $\varphi(X) = I_{\{x_1 \leq 0\}}$, 则 $E(\varphi(X)) = g(\theta)$

在 $T = t$ 的条件下,

$$E(\varphi(X)|T=t) = P(x_1 \leq 0|T=t) = P(x_1 - t \leq -t|T=t)$$

由于 $\text{COV}(X_1 - T, T) = 0$, 因此: $X_1 - T$ 与 T 相互独立, 且 $X_1 - T \sim N(0, \frac{n-1}{n})$

故:

$$E(\varphi(X)|T=t) = \int_{-\infty}^{-t} \frac{\sqrt{n}}{\sqrt{2\pi(n-1)}} \exp\left\{-\frac{n}{2(n-1)}u^2\right\} du = \Phi\left(-\frac{\sqrt{n}}{\sqrt{n-1}}t\right)$$

为 $g(\theta)$ 的 UMVUE。

2.16

证明: (1) $ET(X) = \int_{\theta}^b \frac{T(x)f(x)}{h(\theta)dx} = g(\theta)$ 即 $\int_{\theta}^b T(x)f(x)dx = g(\theta)h(\theta)$

对 θ 求导: $-T(x)f(x)dx = g'(\theta)h(\theta) + h'(\theta)g(\theta)$

将 θ 换为 x : $-T(x) = [g'(\theta)h(\theta) + h'(\theta)g(\theta)]/f(x)$

(2) 由 $\int_{\theta}^b \frac{f(x)}{h(\theta)dx} = 1$ 即 $\int_{\theta}^b f(x)dx = h(\theta)$ 对 θ 求导 $-f(\theta) = h'(\theta)$

$$T(X) = g(x_{(1)}) - \frac{g'(x_{(1)})h(x_{(1)})}{nf(x_{(1)})} = -[g'(x_{(1)})h(x_{(1)}) + nh'(x_{(1)})g(x_{(1)})]/nf(x_{(1)})$$

样本 X_1, X_2, \dots, X_n 的联合密度函数为:

$$P(x_1, x_2, \dots, x_n) \frac{f(x_1) \dots f(x_n)}{h^n(\theta)} I_{(0,+\infty)}(x_{(1)}) I_{(-\infty,b)}(x_{(n)})$$

由因子分解定理知 $X_{(1)}$ 为分布族的充分统计量

下证 $X_{(1)}$ 是完备的, 先求 $X_{(1)}$ 的密度函数。

$$P(X_{(1)} \leq x) = 1 - P(X_{(1)} > x) = 1 - \left[\int_{\theta}^b \frac{f(t)}{h(\theta)} dt \right]^n \quad (x \geq \theta)$$

$\therefore X_{(1)}$ 的密度函数:

$$P(\theta) = -n \left[\int_{\theta}^b \frac{f(t)}{h(\theta)} dt \right]^{n-1} (-1) \frac{f(\theta)}{h(\theta)} = \frac{n}{h(\theta)^2} \left[\int_{\theta}^b f(t) dt \right]^{n-1} f(x) \quad (x \geq \theta)$$

对 $\forall \phi(t), E\phi(t) = \int_{\theta}^b \phi(t) \frac{n}{h(\theta)^2} \left[\int_{\theta}^b f(t) dt \right]^{n-1} f(x) dx$ 因为 $f(x) > 0, h(\theta) > 0$

若 $E\phi(t) = 0$ 则 $\phi(t) = 0$, 故 $X_{(1)}$ 为完备的。

$T(X)$ 为 $X_{(1)}$ 的函数, 只需证 $T(X)$ 为无偏估计即可。

$$\begin{aligned} & \int_{\theta}^b \left(g(x) - \frac{g'(x)h(x)}{nf(x)} \right) \frac{n}{h(\theta)^2} \left[\int_x^b f(t)dt \right]^{n-1} f(x)dx \\ &= \int_{\theta}^b (-g'(x)h(x) - nh'(x)g(x))/h(\theta)^2 \left[\int_x^b f(t)dt \right]^{n-1} dx \\ &= E(-g'(\theta)h(\theta) - h'(\theta)g(\theta))/f(x) \\ &= \int_{\theta}^b (-g'(x)h(x) - h'(x)g(x))/f(x) * \frac{f(x)}{h(\theta)} dx = g(\theta) \end{aligned}$$

$$ET(X) = g(\theta)$$

即 $T(X)$ 为完备充分统计量的函数且为 $g(\theta)$ 的无偏估计
 $g(\theta)$ 的唯一 UMVUE 为

$$T(X) = g(x_{(1)}) - \frac{g'(x_{(1)})h(x_{(1)})}{nf(x_{(1)})}$$

(此题稍微有点问题, 大家可自己思考一下)

2.21 求证: 若 $T_1(X)$, $T_2(X)$ 分别是 $g_1(\theta)$, $g_2(\theta)$ 的 UMVUE, 则 $T_1(X) + T_2(X)$ 是 $g_1(\theta) + g_2(\theta)$ 的 UMVUE。

证明: 为证明此结论, 我们先来证明 $T(X) \in U_g$ 是 $g_1(\theta)$ 的 UMVUE 的充要条件是 $Cov(T(X), U) = 0$, 其中 $U \in U_0$, U_0 为 0 的无偏估计类。

必要性:

设 $T(X)$ 是 $g_1(\theta)$ 的 UMVUE, 则 $U \in U_0$ 和 $a \in R$ 可以表示 $g(\theta)$ 的无偏估计

$$g(X) = T(X) + aU, \text{ 有}$$

$$Var(g(X)) = Var(T(X) + aU) = Var(T(X)) + a^2 Var(U) + 2a Cov(T(X), U) \geq Var(T(X))$$

$$\text{则有 } a^2 Var(U) + 2a Cov(T(X), U) \geq 0,$$

易知, $4Cov^2(T(X), U) \leq 0$, 故只有 $Cov(T(X), U) = 0$ 。

充分性:

设 $T(X)$ 对任一个 $U \in U_0$ 都有 $Cov(T(X), U) = 0$, 则对 $g(\theta)$ 的任何一个无偏估计

$$g(X),$$

$$\text{令 } U = T(X) - g(X), \text{ 有 } E(U) = 0,$$

$$\text{Var}(g(X)) = E(\hat{g} - g(\theta))^2 = E(\hat{g} - T(X) + T(X) - g(\theta))^2 = \text{Var}(U) + \text{Var}(T(X)) + 2\text{Cov}(U, T(X)) \geq \text{Var}(T(X))$$

,

故 $T(X)$ 是 $g(\theta)$ 的 UMVUE。

下面我们来证明本题: $T_1(X)$, $T_2(X)$ 分别是 $g_1(\theta)$, $g_2(\theta)$ 的 UMVUE,

$$\text{则 } E(T_1(X)) = g_1(\theta), E(T_2(X)) = g_2(\theta),$$

$$\text{且有 } \text{Cov}(T_1(X), U) = 0, \text{Cov}(T_2(X), U) = 0,$$

$$\text{所以 } E(T_1(X) + T_2(X)) = g_1(\theta) + g_2(\theta), \text{Cov}(T_1(X) + T_2(X), U) = 0, \text{ 其中 } U \in U_0,$$

综上可得, $T_1(X) + T_2(X)$ 是 $g_1(\theta) + g_2(\theta)$ 的 UMVUE

2.24 对 Poisson 分布 $P(\theta)$

1) 求 $I(\theta)$;

2) 求 $I(\frac{1}{\theta})$;

3) 找一个函数 $g(\cdot)$, 使 $g(\theta)$ 的 Fisher 信息与 θ 无关.

Poisson 分布的分布列为 $P_\theta(x) = \frac{\theta^x}{x!} e^{-\theta}, x \in N^*$.

$$1) S_\theta(x) = \frac{\partial \ln P_\theta(x)}{\partial \theta} = \frac{x}{\theta} - 1;$$

$$\text{故 } I(\theta) = E_\theta(S_\theta(x))^2 = \text{Var}(S_\theta(x)) = \text{Var}\left(\frac{x}{\theta} - 1\right) = \frac{1}{\theta};$$

$$2) \text{ 令 } t = \frac{1}{\theta}, \text{ 则 } P_t(x) = \frac{t^x}{x!} e^{-t}, x \in N^*$$

$$S_t(x) = \frac{\partial \ln P_t(x)}{\partial t} = -\frac{x}{t} + t^{-2},$$

$$\text{故 } I\left(\frac{1}{\theta}\right) = I(t) = E_t(S_t(x))^2 = \text{Var}(S_t(x)) = \text{Var}\left(-\frac{x}{t} + \frac{1}{t^2}\right) = t^{-3} = \theta^3.$$

$$3) S_g(x) = \frac{\partial \ln P_\theta(x)}{\partial g} = \frac{\partial(x \ln \theta - \theta)}{\partial g} = \frac{x(\partial \ln \theta - \partial \theta)}{\partial g};$$

$$I(g(\theta)) = E_g(S_g(x))^2 = \text{Var}(S_g(x)) = \text{Var}\left(\frac{x(\partial \ln \theta - \partial \theta)}{\partial g}\right) = \left(\frac{\partial \ln \theta}{\partial g}\right)^2 \theta = \text{Const}.$$

不妨设 $\text{Const}=1$;

$$\text{则有 } \frac{\partial \ln \theta}{\partial g} = \theta^{-\frac{1}{2}}, \text{ 故 } \frac{\partial \theta}{\partial g} = \theta^{\frac{1}{2}}, \text{ 解得 } g = 2\theta^{\frac{1}{2}}, \text{ 此时 } I(g(\theta))=1.$$

所以可找函数 $g(\theta) = 2\theta^{\frac{1}{2}}$, 使其 Fisher 信息与 θ 无关.

2.24 对 Poisson 分布 $P(\theta)$,

(1) 求 $I(\theta)$;

(2) 求 $I\left(\frac{1}{\theta}\right)$

(3) 找一个函数 $g(\bullet)$, 使 $g(\theta)$ 的 Fisher 信息与 θ 无关。

$$\text{解: } p(x; \theta) = \frac{\theta^x e^{-\theta}}{x!}$$

(1)

$$\begin{aligned} I(\theta) &= -E\left[\frac{\partial^2 \ln p(x; \theta)}{\partial \theta^2}\right] = -E\left[\frac{\partial^2 (x \ln \theta - \theta - \ln x!)}{\partial \theta^2}\right] \\ &= -E\left[\frac{\partial\left(\frac{x}{\theta} - 1\right)}{\partial \theta}\right] = -E\left[-\frac{x}{\theta^2}\right] = \frac{EX}{\theta^2} = \frac{1}{\theta} \end{aligned}$$

(2)

$$\begin{aligned}
 I\left(\frac{1}{\theta}\right) &= -E\left[\frac{\partial^2 \ln p(x; \theta)}{\partial \left(\frac{1}{\theta}\right)^2}\right] = -E\left\{\frac{\partial^2 \left[-x \ln \frac{1}{\theta} - \left(\frac{1}{\theta}\right)^{-1} - \ln x!\right]}{\partial \left(\frac{1}{\theta}\right)^2}\right\} \\
 &= -E\left\{\frac{\partial \left[-x \left(\frac{1}{\theta}\right)^{-1} + \left(\frac{1}{\theta}\right)^{-2}\right]}{\partial \left(\frac{1}{\theta}\right)}\right\} = -E\left[x \left(\frac{1}{\theta}\right)^{-2} - 2 \left(\frac{1}{\theta}\right)^{-3}\right] = -\theta^2 EX + 2\theta^3 = \theta^3
 \end{aligned}$$

(3) 令 $g(\theta) = \theta^a$

$$\begin{aligned}
 I(\theta^a) &= -E\left[\frac{\partial^2 \ln p(x; \theta)}{\partial (\theta^a)^2}\right] = -E\left\{\frac{\partial^2 \left[\frac{x}{a} \ln \theta^a - (\theta^a)^{\frac{1}{a}} - \ln x!\right]}{\partial (\theta^a)^2}\right\} \\
 &= -E\left\{\frac{\partial \left[\frac{x}{a} (\theta^a)^{-1} - \frac{1}{a} (\theta^a)^{\frac{1}{a}-1}\right]}{\partial (\theta^a)}\right\} = -E\left[-\frac{x}{a} (\theta^a)^{-2} - \left(\frac{1}{a^2} - \frac{1}{a}\right) (\theta^a)^{\frac{1}{a}-2}\right] \\
 &= \frac{EX}{a} \theta^{-2a} + \left(\frac{1}{a^2} - \frac{1}{a}\right) \theta^{1-2a} = \frac{1}{a^2} \theta^{1-2a}
 \end{aligned}$$

$$1 - 2a = 0 \Rightarrow a = \frac{1}{2}, \text{ 当 } g(\theta) = \theta^{\frac{1}{2}} \text{ 时, } I\left(\theta^{\frac{1}{2}}\right) = 4.$$

2.34 设 X_1, \dots, X_n 是来自 $N(0, \sigma^2)$ 的一个样本.

(1) 利用二阶矩构造 σ^2 的矩估计, 进而给出 σ 的矩估计 $\hat{\sigma}_1$;

(2) 证明 $E_\sigma |X_1| = \sigma \sqrt{\frac{2}{\pi}}$. 由此给出 σ 的另一矩估计 $\hat{\sigma}_2$;

(3) 比较 $\hat{\sigma}_1$ 和 $\hat{\sigma}_2$ 的 MSE, 解释比较结果.

解: (1) $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n x_i^2, \quad \hat{\sigma}_1 = \sqrt{\frac{1}{n} \sum_{i=1}^n x_i^2}$

$$(2) \int_{-\infty}^{+\infty} |x| \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{x^2}{2\sigma^2}} dx = 2 \int_0^{+\infty} x \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{x^2}{2\sigma^2}} dx = \sigma \sqrt{\frac{2}{\pi}}$$

从而有 $E_\sigma |X_1| = \sigma \sqrt{\frac{2}{\pi}}$.

$$\therefore \hat{\sigma}_2 = \sqrt{\frac{\pi}{2}} |X_1|.$$

(3)

$$MSE(\hat{\sigma}_1) = E\left(\sqrt{\frac{1}{n} \sum_{i=1}^n X_i^2} - \sigma\right)^2 = E(S_n^2 - 2S_n\sigma + \sigma^2)$$

$$MSE(\hat{\sigma}_2) = E\left(\sqrt{\frac{\pi}{2}} |X_1| - \sigma\right)^2 = E\left(\frac{\pi}{2} X_1 - 2\sqrt{\frac{\pi}{2}} |X_1| + \sigma^2\right) = -2\sigma + \sigma^2$$

2.35

(1) 由于 $P(x_1 = -1) = \frac{1-\theta}{2}$; $P(x_1 = 0) = \frac{1}{2}$; $P(x_1 = 1) = \frac{\theta}{2}$.

有似然函数:

$$L = \prod_{x_i=-1} \frac{1-\theta}{2} \prod_{x_i=0} \frac{1}{2} \prod_{x_i=1} \frac{\theta}{2}$$

对数似然:

$$l = \ln L = [\sum 1(x_i = -1)] \ln(1-\theta) + [\sum 1(x_i = 1)] \ln(\theta) - n \ln 2$$

对对数似然函数求导得:

$$-[\sum 1(x_i = -1)]/(1-\theta) + [\sum 1(x_i = 1)]/\theta = 0$$

对上式求解为:

$$\hat{\theta}_1 = \frac{[\sum 1(x_i = 1)]}{[\sum 1(x_i = -1 \text{ 或 } 1)]}$$

对 $\hat{\theta}_1$ 的无偏性, 令 $\sum 1(x_i = 0) = a$

当 $a < n$ 时, $E(\hat{\theta}_1 | a) = \theta$;

当 $a = n$ 时, $E(\hat{\theta}_1 | a) = 0$;

因此, $\hat{\theta}_1$ 是有偏的

(2)

$$E(X) = \frac{1-\theta}{2} \times (-1) + \frac{\theta}{2} = \theta - \frac{1}{2} = \bar{x}$$

$$\hat{\theta}_2 = \frac{1}{2} + \bar{x}$$

(3)

构造 $P(x_i) = -\frac{1}{4}x_i^2 + (\frac{\theta}{2} - \frac{1}{4})x_i + \frac{1}{4}$ 满足题设

$$\text{则有 } S_{\theta}(X) = \frac{2X}{-X^2 + (2\theta - 1)X + 2}$$

$$I_1(\theta) = E(S_{\theta}(X))^2 = \left(\frac{-2}{-1+1-\theta+2}\right)^2 \times P(X=-1) + \left(\frac{2}{-1+2\theta-1+2}\right)^2 \times P(X=1) = \frac{1}{2\theta(1-\theta)}$$

$$I(\theta) = nI_1(\theta) = \frac{n}{2\theta(1-\theta)}$$

$$I^{-1}(\theta) = \frac{2\theta(1-\theta)}{n} \quad \text{因此, } \theta \text{ 的无偏估计的方差的 C-R 下界为 } \frac{2\theta(1-\theta)}{n}$$

2.36 设 X_1, X_2, \dots, X_n 是来自 $U(0, \theta)$, $\theta > 0$ 的一个样本, 则 θ 的 MLE 是 $\hat{\theta}_1 = X_{(n)}$,

$UMVUE$ 是 $\hat{\theta}_2 = \frac{n+1}{n} X_{(n)}$. 试证: 存在一个估计 $\hat{\theta}(x)$, 使

$$MSE_{\theta}(\hat{\theta}) < \min(MSE_{\theta}(\hat{\theta}_1), MSE_{\theta}(\hat{\theta}_2)).$$

证明: 令 $X_{(n)}$ 的分布函数为

$$\begin{aligned} F_{X_{(n)}}(t) &= P(X_{(n)} \leq t) = P(X_1 \leq t, X_2 \leq t, \dots, X_n \leq t) \\ &= [F(t)]^n = \begin{cases} 0, & t < 0; \\ \left(\frac{t}{\theta}\right)^n, & 0 \leq t < \theta; \\ 1, & t \geq \theta. \end{cases} \end{aligned}$$

则 $X_{(n)}$ 的密度函数为 $f_{X_{(n)}}(t) = n \left(\frac{t}{\theta}\right)^{n-1} \frac{1}{\theta} (0 \leq t < \theta)$.

$$\text{因此, } EX_{(n)} = \int_0^{\theta} t \bullet n \left(\frac{t}{\theta}\right)^{n-1} \frac{1}{\theta} dt = \frac{n}{n+1} \theta.$$

$$EX_{(n)}^2 = \int_0^{\theta} t^2 \bullet n \left(\frac{t}{\theta}\right)^{n-1} \frac{1}{\theta} dt = \frac{n}{n+2} \theta^2.$$

$$\text{那么, } Var(X_{(n)}) = EX_{(n)}^2 - (EX_{(n)})^2 = \frac{n}{(n+2)(n+1)^2} \theta^2.$$

令 $\hat{\theta}(t) = t X_{(n)}$, 则 $MSE_{\theta}(\hat{\theta}(t)) = [E(\hat{\theta}(t)) - \theta]^2 + Var(\hat{\theta}(t))$

$$\begin{aligned} &= (-1)^2 \theta^2 + \frac{nt^2}{(n+2)(n+1)^2} \theta^2 \\ &= (-) \theta^2 \end{aligned}$$

故由上式可得：当 $t=$ 时， $MSE_{\theta}(\hat{\theta}(t))$ 取得最小值。

因为 $\hat{\theta}_1 = \hat{\theta}(1)$ ， $\hat{\theta}_2 = \hat{\theta}()$ ，

所以，当 $\hat{\theta} = X_{(n)}$ 时，有

$$MSE_{\theta}(\hat{\theta}) < \min(MSE_{\theta}(\hat{\theta}_1), MSE_{\theta}(\hat{\theta}_2)).$$

3.2 设 $X = (X_1, \dots, X_n)$ 是来自正态分布族 $\{N(0, \sigma^2): 0 < \sigma^2 < \infty\}$ 的样本, 考虑原假设 $H_0: \sigma^2 = 1$ 对备择假设 $H_1: \sigma^2 = \sigma_1^2 (\sigma_1^2 > 1)$ 的检验问题, 取水平为 $\alpha (0 < \alpha < 1)$ 。试求其 **MPT**。

$$\text{解: } p(x; \sigma^2) = (\sqrt{2\pi}\sigma)^{-1} \exp\left\{-\frac{x^2}{2\sigma^2}\right\}$$

似然比为 $\lambda(x) = \frac{\prod p(x_i; \sigma_1^2)}{\prod p(x_i; 1)} = (\sigma_1^2)^{-\frac{n}{2}} \exp\left\{-\frac{\sum x_i^2}{2} \left(\frac{1}{\sigma_1^2} - 1\right)\right\}$, 取 $T(x) = \sum x_i^2$, 拒绝域为 $W = \{x: \lambda(x) \geq \lambda_0\} = \{x: T(x) \geq c\}$ 。

当 $H_0: \sigma^2 = 1$ 成立时, $T(x) = \sum x_i^2 \sim \chi^2(n)$, 则拒绝域为 $W = \{x: \sum x_i^2 \geq \chi_{1-\alpha}^2(n)\}$ 。

$$\text{则 MPT 为 } \phi(x) = \begin{cases} 1, \sum x_i^2 \geq \chi_{1-\alpha}^2(n) \\ 0, \sum x_i^2 < \chi_{1-\alpha}^2(n) \end{cases}.$$

3.3 设 $X = (X_1, \dots, X_n)$ 是来自均匀分布族 $\{R(0, \theta): \theta > 0\}$ 的样本, 考虑原假设 $H_0: \theta = 1$ 对备择假设 $H_1: \theta = \theta_1 (\theta_1 < 1)$ 的检验问题, 取水平为 $\alpha (0 < \alpha < 1)$ 。试求其 **MPT**。

$$\text{解: } p(x; \theta) = \begin{cases} \theta^{-1}, 0 \leq x \leq \theta \\ 0, \text{otherwise} \end{cases}$$

$$\text{似然比为 } \lambda(x) = \frac{\prod p(x_i; \theta_1)}{\prod p(x_i; 1)} = \begin{cases} \theta_1^{-n}, 0 < x_{(n)} \leq \theta_1 \\ 0, \theta_1 < x_{(n)} < 1 \end{cases}$$

$$\text{则 MPT 为 } \phi(x) = \begin{cases} 1, 0 < x_{(n)} \leq c \\ 0, c < x_{(n)} < 1 \end{cases}, \quad c \text{ 由 } E[\phi(x)|\theta=1] = \alpha \text{ 确定。}$$

当 $H_0: \theta = 1$ 成立时, $X_{(n)}$ 的密度函数为 $p(t) = nt^{n-1} (0 < t < 1)$, 由 $\int_0^c nt^{n-1} dt = \alpha$, 推得 $c = \sqrt[n]{\alpha}$ 。

$$\text{则 } \phi(x) = \begin{cases} 1, 0 < x_{(n)} \leq \sqrt[n]{\alpha} \\ 0, \sqrt[n]{\alpha} < x_{(n)} < 1 \end{cases}.$$

3.3 设 $X = (X_1, X_2, \dots, X_n)$ 是来自均匀分布族 $\{R(0, \theta): \theta > 0\}$ 的样本, 考虑原假设 $H_0: \theta = 1$ 对备择假设 $H_1: \theta = \theta_1 (\theta_1 < 1)$ 的检验问题。取水平为 $\alpha (0 < \alpha < 1)$ 。试求 **MPT**。

$$\text{解:似然比统计量}\lambda(x)=\frac{\prod_{i=1}^n p(x_i;\theta_1)}{\prod_{i=1}^n p(x_i;1)}=\begin{cases} \theta_1^{-n} & 0 < x_{(n)} < \theta_1 \\ 0 & \theta_1 \leq x_{(n)} \leq 1 \end{cases},$$

其中 $x_{(n)} = \max\{x_1, x_2, \dots, x_n\}$.

在原假设 H_0 成立时 $\lambda(x)$ 的分布为退化分布。令 $G(\lambda) = P\{\lambda(x) > \lambda | \theta = 1\}$, 则当 $\lambda > \theta_1^{-n}$ 时,

$$G(\lambda) = P\{\lambda(x) > \lambda\} = P\{0 < x_{(n)} < \theta_1\} = \int_0^{\theta_1} n t^{n-1} dt = \theta_1^{-n}, \quad \text{则} \quad ,$$

$0 = G(\theta_1^{-n}) < \alpha < G(\theta_1^{-n} - 0) = \theta_1^{-n} < 1$ 。由 N-P 基本引理可知, 取 $k = \theta_1^{-n}$, 则 MPT 为 $\phi(1) = 1 (\theta_1 \leq x_{(n)} \leq 1)$, 而在 $0 < x_{(n)} < \theta_1$ 时, $\phi(x)$ 的值需由 $E[\phi(1) | \phi(1) = 1]$ 确定。

3.5 设样本 $X = (X_1, \dots, X_{100})$ 来自二点分布族 $\{b(1, p): 0 \leq p \leq 1\}$. 试求检验问题: $H_0: p \leq 0.01$ 对 $H_1: p > 0.01$ 的水平 $\alpha = 0.05$ 的 UMPT.

解: 因为样本 $X = (X_1, \dots, X_{100})$ 来自二点分布族 $\{b(1, p): 0 \leq p \leq 1\}$. 故样本的联合密度函数为

$$p(x; p) = p^{\sum_{i=1}^{100} x_i} (1-p)^{(n - \sum_{i=1}^{100} x_i)} = (1-p)^n \exp\left(\ln\left(\frac{p}{1-p}\right) \sum_{i=1}^{100} x_i\right).$$

其中 $Q(p) = \ln \frac{p}{1-p}$ 为 p 的严格单调递增函数.

故由定理 3.8 知, 存在水平为 $\alpha = 0.05$ 的 UMPT 的检验函数, 其仅依赖于充分统计量

$T(X) = \sum_{i=1}^{100} x_i$, 拒绝域为 $W = \{x: T(x) \geq c\}$, 其中 c 由 $E_p \Phi(T(X)) = 0.05$ 确定.

从而

$$E_p \Phi(T(X)) = P(T(X) \geq c) = 0.05. \quad (1)$$

在 $p = 0.01$ 时, $T(X) \sim b(100, 0.01)$. (1) 式可转化为 $P\left(\frac{T(X)-1}{\sqrt{0.99}} < \frac{c-1}{\sqrt{0.99}}\right) = 0.95$, 由中心

极限定理知, $\phi\left(\frac{c-1}{\sqrt{0.99}}\right) = 0.95$. 解得 $c = \sqrt{0.99} U_{0.95} + 1$

由此该问题水平为 $\alpha = 0.05$ 的 UMPT 检验函数为:

$$\phi(T(X)) = \begin{cases} 1, & \sum_{i=1}^{100} x_i \geq c \\ 0, & \sum_{i=1}^{100} x_i < c \end{cases}$$

其中 $c = \sqrt{0.99}U_{0.95} + 1$.

3.6 (定理 3.7 的推广) 设概率密度族 $\{p(x; \theta) : \theta \in \Theta \subseteq R\}$ 关于 \mathbf{x} 具有非降 MLR。

试证明：

(1) 若 X_1, \dots, X_n 是来自该 MLR 分布族的一个样本，并且 $\psi(x_1, \dots, x_n)$ 关于每一个 x_i 都是非降的，则 $E_\theta \psi(X_1, \dots, X_n)$ 是 θ 的一个非降函数；

(2) 若函数 $\psi(x)$ 具有性质：存在点 x_0 使得在 $x < x_0$ 时， $\psi(x) \leq 0$ ，而在 $x > x_0$ 时， $\psi(x) \geq 0$ ，则 $E_\theta \psi(X)$ 或者总是正的，或者总是负的，或者存在点 θ_0 使得在 $\theta < \theta_0$ 时， $E_\theta \psi(X) \leq 0$ ，而在 $\theta > \theta_0$ 时， $E_\theta \psi(X) \geq 0$ 。

(1) 证明：设 $\theta_1 < \theta_2$ ，令 $A = \left\{ (x_1, x_2, \dots, x_n) : \prod_{i=1}^n p(x_i; \theta_1) < \prod_{i=1}^n p(x_i; \theta_2) \right\}$ ，

$$B = \left\{ (x_1, x_2, \dots, x_n) : \prod_{i=1}^n p(x_i; \theta_1) > \prod_{i=1}^n p(x_i; \theta_2) \right\}$$

对任意 $(x_1^{(1)}, x_2^{(1)}, \dots, x_n^{(1)}) \in A$ 和 $(x_1^{(2)}, x_2^{(2)}, \dots, x_n^{(2)}) \in B$ ，有

$$\lambda(x_1^{(1)}, x_2^{(1)}, \dots, x_n^{(1)}) = \frac{\prod_{i=1}^n p(x_i; \theta_2)}{\prod_{i=1}^n p(x_i; \theta_1)} > 1, \quad \lambda(x_1^{(2)}, x_2^{(2)}, \dots, x_n^{(2)}) = \frac{\prod_{i=1}^n p(x_i; \theta_2)}{\prod_{i=1}^n p(x_i; \theta_1)} < 1$$

因为似然比 $\lambda(x_1, x_2, \dots, x_n)$ 是 (x_1, x_2, \dots, x_n) 的非降函数，则由

$$\lambda(x_1^{(1)}, x_2^{(1)}, \dots, x_n^{(1)}) > \lambda(x_1^{(2)}, x_2^{(2)}, \dots, x_n^{(2)}) \rightarrow (x_1^{(1)}, x_2^{(1)}, \dots, x_n^{(1)}) \geq (x_1^{(2)}, x_2^{(2)}, \dots, x_n^{(2)})$$

由于 $\psi(x_1, x_2, \dots, x_n)$ 是 (x_1, x_2, \dots, x_n) 的一个非降函数，所以

$$\psi(x_1^{(1)}, x_2^{(1)}, \dots, x_n^{(1)}) \geq \psi(x_1^{(2)}, x_2^{(2)}, \dots, x_n^{(2)})$$

$$\text{令} \quad a = \inf \{ \psi(x_1, x_2, \dots, x_n) : (x_1, x_2, \dots, x_n) \in A \},$$

$$b = \sup \{ \psi(x_1, x_2, \dots, x_n) : (x_1, x_2, \dots, x_n) \in B \}$$

则有 $a \geq b$ 从而

$$\begin{aligned}
& E_{\theta_2}\psi(x_1, x_2, \cdots x_n) - E_{\theta_1}\psi(x_1, x_2, \cdots x_n) \\
&= \int \psi(x_1, x_2, \cdots x_n) \bullet \left[\prod_{i=1}^n p(x_i; \theta_2) - \prod_{i=1}^n p(x_i; \theta_1) \right] du(x) \\
&= \int_A \psi(x_1, x_2, \cdots x_n) \left[\prod_{i=1}^n p(x_i; \theta_2) - \prod_{i=1}^n p(x_i; \theta_1) \right] du(x) + \\
&\quad \int_B \psi(x_1, x_2, \cdots x_n) \left[\prod_{i=1}^n p(x_i; \theta_2) - \prod_{i=1}^n p(x_i; \theta_1) \right] du(x) \\
&\geq a \bullet \int_A \left[\prod_{i=1}^n p(x_i; \theta_2) - \prod_{i=1}^n p(x_i; \theta_1) \right] du(x) + \\
&\quad b \bullet \int_B \left[\prod_{i=1}^n p(x_i; \theta_2) - \prod_{i=1}^n p(x_i; \theta_1) \right] du(x)
\end{aligned}$$

由于 $\int_{A \cup B} \left[\prod_{i=1}^n p(x_i; \theta_2) - \prod_{i=1}^n p(x_i; \theta_1) \right] du(x) = 0$,

所以 $\int_B \left[\prod_{i=1}^n p(x_i; \theta_2) - \prod_{i=1}^n p(x_i; \theta_1) \right] du(x) = - \int_A \left[\prod_{i=1}^n p(x_i; \theta_2) - \prod_{i=1}^n p(x_i; \theta_1) \right] du(x)$, 从而

$$E_{\theta_2}\psi(x_1, x_2, \cdots x_n) - E_{\theta_1}\psi(x_1, x_2, \cdots x_n) \geq (a-b) \bullet \int_A \left[\prod_{i=1}^n p(x_i; \theta_2) - \prod_{i=1}^n p(x_i; \theta_1) \right] du(x) \geq 0$$

所以 $E_{\theta}\psi(x_1, x_2, \cdots x_n)$ 是 θ 的一个非降函数。

$$(2) \quad E_{\theta}\psi(X) = \int_{-\infty}^{+\infty} \psi(x) p(x; \theta) du(x) = \int_{-\infty}^{x_0} \psi(x) p(x; \theta) du(x) + \int_{x_0}^{+\infty} \psi(x) p(x; \theta) du(x)$$

情况 1: $\forall \theta$, 当 $x < x_0$ 时, $p(x; \theta) > 0$; 当 $x > x_0$ 时, $p(x; \theta) < 0$, 则 $E_{\theta}\psi(X)$ 为负的;

情况 2: $\forall \theta$, 当 $x < x_0$ 时, $p(x; \theta) < 0$; 当 $x > x_0$ 时, $p(x; \theta) > 0$, 则 $E_{\theta}\psi(X)$ 为正的;

情况 3: 当 $x < x_0$, $\theta < \theta_0$ 时, $p(x; \theta) > 0$; 当 $x > x_0$, $\theta < \theta_0$ 时, $p(x; \theta) < 0$, 则 $E_{\theta}\psi(X) \leq 0$;

当 $x < x_0$, $\theta > \theta_0$ 时, $p(x; \theta) < 0$; 当 $x > x_0$, $\theta > \theta_0$ 时, $p(x; \theta) > 0$, 则 $E_{\theta}\psi(X) \geq 0$

2.31 设 $(X_i, Y_i), i=1, \dots, n$ 为独立同分布变量, $\Pr(X_i > 0) = 1$, $EX_1^2 < \infty, EY_1^2 < \infty$ 。

定义 $\theta = EY_1 / EX_1$, 证明

$$\sqrt{n} \left(\frac{\bar{Y}}{\bar{X}} - \theta \right) \xrightarrow{L} N(0, V)$$

并求 V 。

证明: 令 $Z_i = \frac{Y_i}{X_i} - \theta$, 则 Z_1, Z_2, \dots, Z_n 为相互独立随机变量,

$$\sum_{i=1}^n Z_i = \frac{\sum_{i=1}^n Y_i}{\bar{X}} - n\theta, \quad \bar{Z} = \frac{\sum_{i=1}^n Z_i}{n} = \frac{\sum_{i=1}^n Y_i}{\sum_{i=1}^n X_i} - \theta$$

$$E\left(\frac{\sum_{i=1}^n Y_i}{\sum_{i=1}^n X_i} - \theta\right) = \frac{E(\sum_{i=1}^n Y_i)}{E(\sum_{i=1}^n X_i)} - \theta = \frac{E(Y_1)}{E(X_1)} - \theta = 0$$

$$\text{Var}\left(\frac{\sum_{i=1}^n Y_i}{\sum_{i=1}^n X_i} - \theta\right) = \frac{\text{Var}(Y_1)}{\text{Var}(X_1)}$$

所以

$$\sqrt{n} \bullet \frac{\bar{Z} - 0}{\sqrt{\frac{n \text{Var}(Y_1)}{\text{Var}(X_1)}}} \xrightarrow{L} N(0, 1)$$

即

$$\sqrt{n} \bullet \left(\frac{\bar{Y}}{\bar{X}} - \theta \right) \xrightarrow{L} N\left(0, \frac{n \text{Var}(Y_1)}{\text{Var}(X_1)}\right)$$

$$\text{所以 } V = \frac{n \text{Var}(Y_1)}{\text{Var}(X_1)}$$

3.8 设 $X = (X_1, \dots, X_n)$ 是来自带有位置参数的指数分布总体的样本, 总体的密度

函数为 $p(x; \theta) = \begin{cases} \exp\{-(x - \theta)\}, & x \geq \theta \\ 0, & \text{otherwise} \end{cases}$ 。考虑原假设 $H_0: \theta = 0$ 对备择假设 $H_1: \theta > 0$

的检验问题, 取水平为 $\alpha (0 < \alpha < 1)$ 。试求其 UMPT。

解: 首先考虑原假设 $H_0: \theta = 0$ 对备择假设 $H_1: \theta = \theta_1 (\theta_1 > 0)$ 的检验问题, 取水平

为 $\alpha(0 < \alpha < 1)$ 。

$$\text{似然比为 } \lambda(x) = \frac{\prod p(x_i; \theta_1)}{\prod p(x_i; 0)} = \begin{cases} e^{n\theta_1}, & x_{(1)} \geq \theta_1 \\ 0, & 0 < x_{(1)} < \theta_1 \end{cases}$$

$$\text{则 MPT 为 } \phi(x) = \begin{cases} 1, & x_{(1)} \geq c \\ 0, & 0 < x_{(1)} < c \end{cases}, \quad c \text{ 由 } E[\phi(x)|\theta=0] = \alpha \text{ 确定。}$$

当 $H_0: \theta=0$ 成立时, $X_{(1)}$ 的密度函数为 $p(t) = n \left(1 - \int_0^t e^{-x} dx \right)^{n-1} e^{-t} = ne^{-nt} (t \geq 0)$, 由

$$\int_c^{+\infty} ne^{-nt} dt = \alpha, \quad \text{推得 } c = -\frac{\ln \alpha}{n}。$$

$$\text{则 } \phi(x) = \begin{cases} 1, & x_{(1)} \geq -\frac{\ln \alpha}{n} \\ 0, & 0 < x_{(1)} < -\frac{\ln \alpha}{n} \end{cases}。$$

由于这个检验与 θ_1 的具体数值无关, 只要求 $\theta_1 > 0$, 故这个检验 $\phi(x)$ 是原假设

$H_0: \theta=0$ 对备择假设 $H_1: \theta > 0$ 的 UMPT。

3.11 设 $T(x)$ 的密度函数如(3.26)式所示, 其中 $c(\theta) > 0$ 。单边假设检验问题: 原假设 $H_0: \theta \leq \theta_0$ 对备择假设 $H_{01}: \theta > \theta_0$ 的水平为 $\alpha(0 < \alpha < 1)$ 的 UMP 检验 $\phi(T)$ 如(3.19)所示, 即为

$$\phi(T) = \begin{cases} 1 & T > c \\ r & T = c \\ 0 & T < c \end{cases}$$

其中常数 $r(0 \leq r \leq 1)$ 和 c 由(3.20)式, 即 $E_{\theta_0}(\phi(T)) = \alpha$ 确定。我们知道这个检验的势函数 $g(\theta) = E_{\theta}(\phi(T))$ 是非降的, 且在集合 $\{\theta: (0 < g(\theta) < 1)\}$ 上是严格增加的, 证明 $g'(\theta_0) > 0$

解: 由定理 3.14 可知

$$g'(\theta) = \frac{c'(\theta)}{c(\theta)} E_{\theta}(\phi(T)) + E_{\theta}(T\phi(T))$$

由习题 3.10 可知 $E_{\theta}(T) = -\frac{c'(\theta)}{c(\theta)}$, 代入上式得

$$g'(\theta) = -E_{\theta}(T)E_{\theta}(\phi(T)) + E_{\theta}(T\phi(T))$$

又 $E_{\theta_0}(\phi(T)) = \alpha$

要证明 $g'(\theta_0) > 0$, 即证明, $\alpha E_{\theta_0}(T) < E_{\theta_0}(T\phi(T))$

即证明, $\alpha T < T\phi(T)$

令 $\phi(T) = \begin{cases} 1 & T > 0 \\ 0 & T < 0 \end{cases}$, 取 $\alpha P_{\omega}(T > 0)$, 则 $E_{\omega}(\phi(T)) = \alpha$, 当 $T > 0$ 时有 $\alpha T < T\phi(T)$, 当 $T < 0$ 时有 $\alpha T < T\phi(T)$, 故命题得证。

3.13 设样本 $X = (X_1, \dots, X_m)$ 和样本 $Y = (Y_1, \dots, Y_n)$ 互相独立. 他们分别来自正态总体 $N(\mu_1, \sigma^2)$ 和 $N(\mu_2, \sigma^2)$, 其中: $-\infty < \mu_1 < \infty, -\infty < \mu_2 < \infty, \sigma^2 > 0$. 在 $\mu_1 = \mu_2 = \mu$ 时, 试证明: V 的分布与参数 σ^2 和 μ 无关, V 的分布关于原点对称, 其中

$$V = \frac{U}{\sqrt{T_2 - \frac{T_1^2}{m+n}}}, \quad U = \bar{Y} - \bar{X}$$

$$T_1 = m\bar{X} + n\bar{Y}, \quad T_2 = \sum_{i=1}^m X_i^2 + \sum_{i=1}^n Y_i^2$$

证明:

$$X_i \sim N(\mu_1, \sigma^2), i=1, 2, \dots, m; Y_i \sim N(\mu_2, \sigma^2), i=1, 2, \dots, n$$

$$\bar{X} \sim N\left(\mu_1, \frac{\sigma^2}{m}\right), \bar{Y} \sim N\left(\mu_2, \frac{\sigma^2}{n}\right)$$

$$\text{在 } \mu_1 = \mu_2 = \mu \text{ 时, } U = \bar{Y} - \bar{X} \sim N\left(0, \frac{\sigma^2}{m} + \frac{\sigma^2}{n}\right)$$

$$\frac{U}{\sigma \sqrt{\frac{1}{m} + \frac{1}{n}}}} \sim N(0, 1), \quad T_1^2 = (m\bar{X} + n\bar{Y})^2 = \left(\sum_{i=1}^m X_i + \sum_{i=1}^n Y_i\right)^2$$

$$T_2 - \frac{T_1^2}{m+n} = \frac{(m+n)\left(\sum_{i=1}^m X_i^2 + \sum_{i=1}^n Y_i^2\right) - \left(\sum_{i=1}^m X_i + \sum_{i=1}^n Y_i\right)^2}{m+n}$$

$$\text{令 } s = m+n, Z_i = X_i (i=1, \dots, m), Z_{m+j} = Y_j (j=1, \dots, n), \text{ 则 } \sum_{i=1}^s Z_i = \sum_{i=1}^m X_i + \sum_{i=1}^n Y_i$$

$$T_2 - \frac{T_1^2}{m+n} = \frac{(m+n)\left(\sum_{i=1}^m X_i^2 + \sum_{i=1}^n Y_i^2\right) - \left(\sum_{i=1}^m X_i + \sum_{i=1}^n Y_i\right)^2}{m+n}$$

$$\begin{aligned}
T_2 - \frac{T_1^2}{m+n} &= \frac{s \left(\sum_{i=1}^s Z_i^2 \right) - \left(\sum_{i=1}^s Z_i \right)^2}{s} = \sum_{i=1}^s Z_i^2 - \frac{1}{s} \left(\sum_{i=1}^s Z_i \right)^2 \\
&= \sum_{i=1}^s Z_i^2 - \sum_{i=1}^s Z_i \bar{Z} - \sum_{i=1}^s Z_i \bar{Z} + s(\bar{Z})^2 + \sum_{i=1}^s Z_i \bar{Z} - s(\bar{Z})^2 \\
&= \sum_{i=1}^s (Z_i - \bar{Z})^2
\end{aligned}$$

$$\frac{T_2 - \frac{T_1^2}{m+n}}{\sigma^2} = \frac{\sum_{i=1}^s (Z_i - \bar{Z})^2}{\sigma^2} \sim \chi^2(s-1) = \chi^2(m+n-1)$$

$$\frac{\frac{U}{\sigma \sqrt{\frac{n+m}{nm}}}}{\sqrt{\frac{T_2 - \frac{T_1^2}{m+n}}{\sigma^2}}} \sim t(m+n-1), \quad \sqrt{\frac{mn}{n+m}} \frac{U}{\sqrt{T_2 - \frac{T_1^2}{m+n}}} = \sqrt{\frac{mn}{n+m}} V \sim t(m+n-1)$$

所以 V 的分布与参数 σ^2 和 μ 无关, V 的分布关于原点对称

3.13 设样本 $X = (X_1, \dots, X_n)$ 来自正态总体 $N(\mu, \sigma^2)$, 其中 $-\infty < \mu < \infty, \sigma^2 > 0$.

在 $\mu = 0$ 时, 试证明 ω 的分布与参数 σ^2 无关, 且 ω 的分布关于原点对称, 其中,

$$\omega = \frac{\bar{X}}{\sqrt{\sum_{i=1}^n X_i^2}}$$

证明:

当 $\mu = 0$ 时, 每个样本 $X_i \sim N(0, \sigma^2)$, $i = 1, \dots, n$, 所以 $\bar{X} \sim N\left(0, \frac{\sigma^2}{n}\right)$

$$\frac{\sqrt{n}}{\sigma} \bar{X} \sim N(0, 1)$$

$$\frac{1}{\sigma^2} \sum_{i=1}^n X_i^2 \sim \chi^2(n)$$

所以得到,

$$\omega = n \frac{\frac{\sqrt{n}}{\sigma} \bar{X}}{\left(\sqrt{\frac{1}{n\sigma^2} \sum_{i=1}^n X_i^2} \right)} \sim nt(n)$$

所以 ω 的分布与参数 σ^2 无关，由于 $t(n)$ 是关于原点对称，所以 ω 的分布关于原点对称。

3.17

证： $E_0[(\text{错误！未找到引用源。})(\text{错误！未找到引用源。})] = -E_0[\text{错误！未找到引用源。}]$

证明： $E_0[(\text{错误！未找到引用源。})(\text{错误！未找到引用源。})]$

=错误！未找到引用源。

= 错误！未找到引用源。

$E_0[\text{错误！未找到引用源。}]$

=错误！未找到引用源。

=错误！未找到引用源。

=错误！未找到引用源。

=错误！未找到引用源。

=-错误！未找到引用源。

= $-E_0[(\text{错误！未找到引用源。})(\text{错误！未找到引用源。})]$

3.18 设 $(X_1, Y_1), \dots, (X_n, Y_n)$ 为来自二元正态分布 $N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ 的样本，其中 ρ 是相关系数。试求题 $H_0: \rho=0$ 对 $H_1: \rho \neq 0$ 的似然比检验。

解：对于服从参数为 (μ, Σ) 的多元正态分布

$$\text{其分布函数为, } p(X) = \frac{1}{(2\pi)^p |\Sigma|} \exp\left\{-\frac{(X-\mu)^T \Sigma^{-1} (X-\mu)}{2}\right\}$$

易知其参数的极大似然估计为, $\hat{\mu} = \bar{X}$, $\hat{\Sigma} = S$

$$\text{其中 } S \text{ 的每一元素 } S_{ij} = \frac{1}{n} \sum_{i=1}^n (X_i - \hat{\mu}_i)(X_j - \hat{\mu}_j)$$

又在二元正态分布下,

$$\hat{\mu}_1 = \frac{1}{n} \sum_{i=1}^n X_{1i}, \quad \hat{\mu}_2 = \frac{1}{n} \sum_{i=1}^n X_{2i}$$

$$\hat{\sigma}_1^2 = \frac{1}{n} \sum_{i=1}^n (X_{1i} - \hat{\mu}_1)^2, \quad \hat{\sigma}_2^2 = \frac{1}{n} \sum_{i=1}^n (X_{2i} - \hat{\mu}_2)^2$$

$$\hat{\rho} = \frac{1}{n \hat{\sigma}_1 \hat{\sigma}_2} \sum_{i=1}^n (X_{1i} - \hat{\mu}_1)(X_{2i} - \hat{\mu}_2)$$

$$\prod_{i=1}^n p(X_i; \hat{\mu}_1, \hat{\mu}_2, \hat{\sigma}_1^2, \hat{\sigma}_2^2, \hat{\rho})$$

则似然比检验为, $\lambda(x) = \frac{\prod_{i=1}^n p(X_i; \hat{\mu}_1, \hat{\mu}_2, \hat{\sigma}_1^2, \hat{\sigma}_2^2, \hat{\rho})}{\prod_{i=1}^n p(X_i; \hat{\mu}_1, \hat{\mu}_2, \hat{\sigma}_1^2, \hat{\sigma}_2^2, \rho=0)}$

$$2\ln(X) = \sum_{i=1}^n \left\{ \left[\frac{(X_{1i} - \mu_1)^2}{\hat{\sigma}_1^2} + \frac{(X_{2i} - \mu_2)^2}{\hat{\sigma}_2^2} \right] - \frac{2\hat{\rho}}{1 - \hat{\rho}^2} \left[\frac{(X_{1i} - \mu_1)(X_{2i} - \mu_2)}{\hat{\sigma}_1 \hat{\sigma}_2} \right] \right\}$$

又 $2\ln(X)$ 服从 $\chi^2(1)$, 则在显著性水平为 α 的情况下, 如果有 $2\ln(X) > \chi_{\alpha}^2(1)$ 则拒绝原假设, 否则不拒绝原假设。

3.18 设 $(X_1, Y_1), \dots, (X_n, Y_n)$ 为来自二元正态分布 $N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ 的样本, 其中 ρ 是相关函数。试求检验问题 $H_0: \rho = 0$ 对 $H_1: \rho \neq 0$ 的似然比检验。

解: 若 $X = (X_1, X_2, \dots, X_p)$ 服从参数为 (μ, Σ) 的 p 元正态分布,

其分布密度函数为:

$$p(x) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp \left\{ -\frac{1}{2} (X - \mu)' \Sigma^{-1} (X - \mu) \right\}.$$

易求出其参数的极大似然估计为: $\hat{\mu} = \bar{X}, \hat{\Sigma} = S$.

其中, S 的 ij 元为 $S_{ij} = \frac{1}{n} \sum_{a=1}^n (X_{ai} - \hat{\mu}_i)(X_{aj} - \hat{\mu}_j)$.

故在二元分布下, 有 $\Sigma = \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}$.

所以可求得参数的 MLE 为: $\hat{\mu}_1 = \frac{1}{n} \sum X_i, \hat{\mu}_2 = \frac{1}{n} \sum Y_i$;

$$\hat{\sigma}_1^2 = \frac{1}{n} \sum (X_i - \hat{\mu}_1)^2, \hat{\sigma}_2^2 = \frac{1}{n} \sum (Y_i - \hat{\mu}_2)^2;$$

$$\hat{\rho} = \frac{1}{n \hat{\sigma}_1 \hat{\sigma}_2} \sum (X_i - \hat{\mu}_1)(Y_i - \hat{\mu}_2).$$

则似然比检验为:

$$\lambda(X) = \frac{\prod_{i=1}^n p(X_i, Y_i; \hat{\mu}_1, \hat{\mu}_2, \hat{\sigma}_1^2, \hat{\sigma}_2^2, \hat{\rho})}{\prod_{i=1}^n p(X_i, Y_i; \hat{\mu}_1, \hat{\mu}_2, \hat{\sigma}_1^2, \hat{\sigma}_2^2, \rho=0)}.$$

$$\therefore 2 \ln \lambda(X) = \sum_{i=1}^n \left\{ \frac{\hat{\rho}^2}{1 - \hat{\rho}^2} \left[\frac{(X_i - \hat{\mu}_1)^2}{\hat{\sigma}_1^2} + \frac{(Y_i - \hat{\mu}_2)^2}{\hat{\sigma}_2^2} \right] - \frac{2\hat{\rho}}{1 - \hat{\rho}^2} \frac{(X_i - \hat{\mu}_1)(Y_i - \hat{\mu}_2)}{\hat{\sigma}_1 \hat{\sigma}_2} \right\}$$

由定理 3.18 可知:

在原假设 H_0 为真时, $2 \ln \lambda(X)$ 随着 n 的增大而依分布收敛 $\chi^2(1)$.

因此, 在显著性水平 α 下, 如果 $2 \ln \lambda(X) \geq \chi_{1-\alpha}^2(1)$, 则拒绝原假设, 否则不拒绝原假设。

3.19 试证明下述结论:

(1) 接例 3.16,

$$\begin{aligned} 2 \ln \Lambda &= 2 \sum_{i=1}^r n_i \cdot \ln \frac{n_i}{np_{0i}} \\ &= \sum_{i=1}^r \frac{(n_i - np_{0i})^2}{np_{0i}} + \text{依概率收敛于0的量} \end{aligned}$$

(2) 接 3.6.4 节,

$$\begin{aligned} 2 \ln \Lambda &= 2 \sum_{i=1}^r \sum_{j=1}^c n_{ij} \cdot \ln \frac{n \cdot n_{ij}}{n_{i \cdot} \cdot n_{\cdot j}} \\ &= \sum_{i=1}^r \sum_{j=1}^c \frac{\left(n_{ij} - n \hat{p}_{i \cdot} \hat{p}_{\cdot j} \right)^2}{n \hat{p}_{i \cdot} \hat{p}_{\cdot j}} + \text{依概率收敛于0的量} \end{aligned}$$

解:

(1) 例 3.16 的似然比统计量为:

$$\Lambda = \frac{\prod_{i=1}^r \left(\frac{n_i}{n} \right)^{n_i}}{\prod_{i=1}^r (p_{0i})^{n_i}}$$

$$\text{所以 } 2 \ln \Lambda = 2 \sum_{i=1}^r n_i \cdot \ln \frac{n_i}{np_{0i}} = 2 \sum_{i=1}^r n_i \cdot \ln \left[1 + \frac{(n_i - np_{0i})}{np_{0i}} \right]$$

因为 $\ln(1+x)$ 的 Taylor 展式: $\ln(1+x) = x - \frac{x^2}{2} + o(x^2) \quad (x \rightarrow 0)$

又因为当 H_0 成立时，由伯努利大数定理得 $\frac{n_i - np_{0i}}{np_{0i}} = \frac{\frac{n_i}{n} - p_{0i}}{p_{0i}}$ 依概率收敛于 0。

$$\begin{aligned}
 2 \ln \Lambda &= 2 \sum_{i=1}^r n_i \cdot \ln \left[1 + \frac{(n_i - np_{0i})}{np_{0i}} \right] \\
 &= 2 \sum_{i=1}^r n_i \cdot \left[\frac{n_i - np_{0i}}{np_{0i}} - \frac{1}{2} \left(\frac{n_i - np_{0i}}{np_{0i}} \right)^2 + o \left(\left(\frac{n_i - np_{0i}}{np_{0i}} \right)^2 \right) \right] \\
 &= 2 \sum_{i=1}^r [np_{0i} + (n_i - np_{0i})] \cdot \left[\frac{n_i - np_{0i}}{np_{0i}} - \frac{1}{2} \left(\frac{n_i - np_{0i}}{np_{0i}} \right)^2 + o \left(\left(\frac{n_i - np_{0i}}{np_{0i}} \right)^2 \right) \right] \\
 &= \sum_{i=1}^r \left[\frac{(n_i - np_{0i})^2}{np_{0i}} + 2(n_i - np_{0i}) - \frac{(n_i - np_{0i})^3}{(np_{0i})^2} + o \left(\left(\frac{n_i - np_{0i}}{np_{0i}} \right)^2 \right) \right]
 \end{aligned}$$

因为后面三项都依概率收敛于 0（伯努利大数定理）， $\lim_{n \rightarrow \infty} p(|n_i - np_{0i}| < \varepsilon) = 1$ 。

所以 $2 \ln \Lambda = \sum_{i=1}^r \frac{(n_i - np_{0i})^2}{np_{0i}} +$ 依概率收敛于 0 的量。

(2) 3.6.4 节的似然比统计量为：

$$\Lambda = \frac{\prod_{i=1}^r \prod_{j=1}^c \left(\frac{n_{ij}}{n} \right)^{n_{ij}}}{\prod_{i=1}^r \prod_{j=1}^c \left(\frac{n_{i \cdot}}{n} \cdot \frac{n_{\cdot j}}{n} \right)^{n_{ij}}}$$

$$\text{因为 } 2 \ln \Lambda = 2 \sum_{i=1}^r \sum_{j=1}^c n_{ij} \cdot \ln \frac{n \cdot n_{ij}}{n_{i \cdot} \cdot n_{\cdot j}} = 2 \sum_{i=1}^r \sum_{j=1}^c n_{ij} \cdot \ln \left(1 + \frac{n \cdot n_{ij} - n_{i \cdot} \cdot n_{\cdot j}}{n_{i \cdot} \cdot n_{\cdot j}} \right)$$

又因为在原假设 $H_0: p_{ij} = p_{i \cdot} \cdot p_{\cdot j}$ 成立时， p_{ij} 的 MLE 为 $\hat{p}_{i \cdot} \cdot \hat{p}_{\cdot j} = \left(\frac{n_{i \cdot}}{n} \right) \cdot \left(\frac{n_{\cdot j}}{n} \right)$ 。

$$\begin{aligned}
2 \ln \Lambda &= 2 \sum_{i=1}^r \sum_{j=1}^c n_{ij} \cdot \ln \left(1 + \frac{n \cdot n_{ij} - n_{i \cdot} \cdot n_{\cdot j}}{n_{i \cdot} \cdot n_{\cdot j}} \right) \\
&= 2 \sum_{i=1}^r \sum_{j=1}^c n_{ij} \cdot \left[\frac{n_{ij} - n \hat{p}_{i \cdot} \hat{p}_{\cdot j}}{n \hat{p}_{i \cdot} \hat{p}_{\cdot j}} - \frac{1}{2} \left(\frac{n_{ij} - n \hat{p}_{i \cdot} \hat{p}_{\cdot j}}{n \hat{p}_{i \cdot} \hat{p}_{\cdot j}} \right)^2 + o \left(\left(\frac{n_{ij} - n \hat{p}_{i \cdot} \hat{p}_{\cdot j}}{n \hat{p}_{i \cdot} \hat{p}_{\cdot j}} \right)^2 \right) \right] \\
&= 2 \sum_{i=1}^r \sum_{j=1}^c \left(n \hat{p}_{i \cdot} \hat{p}_{\cdot j} + n_{ij} - n \hat{p}_{i \cdot} \hat{p}_{\cdot j} \right) \left[\frac{n_{ij} - n \hat{p}_{i \cdot} \hat{p}_{\cdot j}}{n \hat{p}_{i \cdot} \hat{p}_{\cdot j}} - \frac{1}{2} \left(\frac{n_{ij} - n \hat{p}_{i \cdot} \hat{p}_{\cdot j}}{n \hat{p}_{i \cdot} \hat{p}_{\cdot j}} \right)^2 + o \left(\left(\frac{n_{ij} - n \hat{p}_{i \cdot} \hat{p}_{\cdot j}}{n \hat{p}_{i \cdot} \hat{p}_{\cdot j}} \right)^2 \right) \right] \\
&= \sum_{i=1}^r \sum_{j=1}^c \left[\frac{\left(n_{ij} - n \hat{p}_{i \cdot} \hat{p}_{\cdot j} \right)^2}{n \hat{p}_{i \cdot} \hat{p}_{\cdot j}} + 2 \left(n_{ij} - n \hat{p}_{i \cdot} \hat{p}_{\cdot j} \right) - \frac{\left(n_{ij} - n \hat{p}_{i \cdot} \hat{p}_{\cdot j} \right)^3}{\left(n \hat{p}_{i \cdot} \hat{p}_{\cdot j} \right)^2} + o \left(\left(\frac{n_{ij} - n \hat{p}_{i \cdot} \hat{p}_{\cdot j}}{n \hat{p}_{i \cdot} \hat{p}_{\cdot j}} \right)^2 \right) \right]
\end{aligned}$$

因为当 H_0 成立时, $\lim_{n \rightarrow \infty} P \left(\left| \frac{n_{ij}}{n} - \hat{p}_{i \cdot} \hat{p}_{\cdot j} \right| < \varepsilon \right) = 1$, 所以后面三项都依概率收敛于 0,

因此有

$$2 \ln \Lambda = \sum_{i=1}^r \sum_{j=1}^c \frac{\left(n_{ij} - n \hat{p}_{i \cdot} \hat{p}_{\cdot j} \right)^2}{n \hat{p}_{i \cdot} \hat{p}_{\cdot j}} + \text{依概率收敛于0的量}$$

3.20

解:

$$H_0: p_{11} = \frac{1-P}{2}, p_{12} = \frac{1-P}{2}, p_{21} = \frac{P^2}{2} + P^*(1-P)$$

$$\lambda(x) = \frac{\sup_{\theta \in \Theta} p(x; \theta)}{\sup_{\theta \in \Theta_0} p(x; \theta)} = \frac{p(x; \hat{\theta})}{p(x; \hat{\theta}_0)}$$

其中 $\hat{\theta}_1$ 为 H_0 不成立时 $(p_{11}, p_{12}, p_{21}, p_{22})$ 的 *MLE*,

则

$$\hat{\theta}_1 = (\hat{p}_{11}, \hat{p}_{12}, \hat{p}_{21}, \hat{p}_{22}) = \left(\frac{n_1}{n}, \frac{n_2}{n}, \frac{n_3}{n}, \frac{n_4}{n} \right),$$

$\hat{\theta}_0$ 为 H_0 成立时的 *MLE*,

又因为

$$p_{11}=\frac{1-P}{2}, p_{12}=\frac{1-P}{2}, p_{21}=\frac{p^2}{2}+p^*(1-p)$$

则

$$L(P)=\frac{n!}{n_1!n_2!n_3!n_4!}p^{n_1+n_3}(1-p)^{n_2+2n_4}(2-p^{n_3}/2^n)$$

令 $\frac{\partial L(P)}{\partial P}=0$

可得

$$(n+n_3+n_4)p^2+(3n+n_2-n_3-n_4)p+2n_1+2n_3=0$$

有

$$\hat{p}=\frac{(3n-n_2+n_3+n_4)-\sqrt{(-3n+n_2-n_3-n_4)^2-4(n+n_3+n_4)(2n_3+2n_1)}}{2(n+n_3+n_4)}$$

所以

$$2\ln \theta(x)=2\ln(\frac{\hat{p}_{11}^{\Lambda n_1}\hat{p}_{12}^{\Lambda n_2}\hat{p}_{21}^{\Lambda n_3}\hat{p}_{22}^{\Lambda n_4}}{p^{\Lambda n_1+n_3}(1-p)^{\Lambda n_2+2n_4}(2-p)^{\Lambda n_3}}2^n)\approx 2.92$$

以为在 H_0 时， $2\ln \theta(x)\overset{L}{\longrightarrow}\chi_{(2)}^2$ 则 p 值为 0.0875，在显著性水平为 5 时，应保留原假设，即不否认该数据与模型相符。

3.23

解：

(1)

H_0 ：A 和 C 相互独立 VS H_1 ：A 和 C 不相互独立

根据题目中所给的表格，绘制下表：

| | | | |
|----|------|------|------|
| | 是 | 否 | 共计 |
| 男 | 686 | 1180 | 1866 |
| 女 | 468 | 1259 | 1727 |
| 共计 | 1154 | 2439 | 3593 |

$$\chi^2(1)=2\sum_{i=2}^2\sum_{j=1}^2n_{ij}\ln\frac{n\cdot n_{ij}}{n_{i\cdot}\cdot n_{\cdot j}}$$

(其中， $n_{11}=686, n_{12}=1180, n_{21}=468, n_{22}=1259, n_{1\cdot}=1866, n_{2\cdot}=1727, n_{\cdot 1}=1154, n_{\cdot 2}=2439, n=3593$)

$$\chi^2(1)=2\times\left(353\times\ln\frac{3593\times686}{1866\times1154}+\cdots1259\times\ln\frac{3593\times1259}{2439\times1727}\right)$$

$$=38.6$$

$$\chi^2_{0.95}(1)=3.84<38.6$$

所以拒绝原假设，即该大学秋季招生有性别歧视，
 男性录取率为： $686/1866=36.8\%$ ，
 女性录取率为： $468/1727=27.1\%$
 可以看出男性录取率更高。

(2)

| | | | | |
|----------------|----|-----|-----|-----|
| B ₁ | | 是 | 否 | 共计 |
| | 男 | 353 | 207 | 560 |
| | 女 | 17 | 8 | 25 |
| | 共计 | 370 | 215 | 585 |
| B ₂ | | 是 | 否 | 共计 |
| | 男 | 120 | 205 | 325 |
| | 女 | 202 | 391 | 593 |
| | 共计 | 322 | 596 | 918 |
| B ₃ | | 是 | 否 | 共计 |
| | 男 | 138 | 279 | 417 |
| | 女 | 131 | 244 | 375 |
| | 共计 | 269 | 523 | 792 |
| B ₄ | | 是 | 否 | 共计 |
| | 男 | 53 | 138 | 191 |
| | 女 | 94 | 299 | 393 |
| | 共计 | 147 | 437 | 584 |
| B ₅ | | 是 | 否 | 共计 |
| | 男 | 22 | 351 | 373 |
| | 女 | 24 | 317 | 341 |
| | 共计 | 46 | 668 | 714 |

$$\begin{aligned}\chi^2(5) &= 2 \sum_{k=1}^5 \sum_{i=1}^2 \sum_{j=1}^2 n_{ijk} \ln \frac{n_{k \cdot} \cdot n_{kij}}{n_{i \cdot k} \cdot n_{\cdot jk}} = \\ &= 2 \times \left(353 \times \ln \frac{585 \times 353}{560 \times 370} + \cdots 8 \times \ln \frac{585 \times 8}{215 \times 25} \right) + \cdots \\ &= 2 \times \left(22 \times \ln \frac{714 \times 22}{373 \times 46} + \cdots 317 \times \ln \frac{714 \times 317}{341 \times 668} \right) \\ &= 2.68\end{aligned}$$

$$\chi_{0.95}^2(5) = 11.7 > 2.68$$

所以不拒绝原假设，即给定 B 后，该大学秋季招生没有性别歧视。

3.26 接例 3.18，在原假设成立时，试证明：

$$\phi_1(x_1) = F(x_1), \quad \sigma_1^2 = \frac{1}{12}$$

$$\phi_2(x_1, x_2) = \phi(x_1, x_2), \quad \sigma_2^2 = \frac{1}{4}$$

$$\text{Var}[U(X_1, X_2, \dots, X_n)] = \frac{2n-1}{6n(n-1)}$$

证明：

$$E[U(X_1, \dots, X_n)] = 0.5$$

$$\phi_1(x_1) = E[\phi(X_1, X_2) | X_1 = x_1] = P(X_2 > -x_1) = 1 - F(-x_1) = F(x_1)$$

$$E[\phi_1(x_1)] = \int_0^1 F(x_1) dF(x_1) = 0.5$$

$$\sigma_1^2 = E[\phi_1(X_1)]^2 - 0.5^2 = \int_0^1 (F(x_1))^2 dF(x_1) - 0.5^2 = \frac{1}{3} - \frac{1}{4} = \frac{1}{12}$$

$$\phi_2(x_1, x_2) = P(x_1 + x_2 > 0) = \phi(x_1, x_2) \quad E[(\phi(x_1, x_2))] = 0.5$$

$$\sigma_2^2 = E[\phi(x_1, x_2)]^2 - 0.5^2 = P(x_1 + x_2 > 0) - \frac{1}{4} = \frac{1}{4}$$

$$\text{Var}[U(X_1, \dots, X_n)] = \binom{n}{2}^{-1} \cdot \sum_{c=1}^2 \binom{2}{c} \cdot \binom{n-2}{2-c} \cdot \sigma_c^2 = \frac{2n-1}{6n(n-1)}$$

4.6

解：因为最大次序统计量 $x_{(n)} = \max\{x_1, x_2, \dots, x_n\}$ 是 N 的 MLE，也是的 N 充分统计量。

又因为 $\frac{x_{(n)}}{N}$ 的密度函数为 $ny^{n-1} (0 \leq y \leq 1)$ ，故取枢轴量 $G(X, N) = \frac{x_{(n)}}{N}$ ，对给定的 $\alpha (0 < \alpha < 1)$ ，只要 a, b 满足 $b^n - a^n = 1 - \alpha$ ，即可得到

$$P_\theta(a \leq \frac{x_{(n)}}{N} \leq b) = 1 - \alpha$$

从而 N 的置信水平为 $1 - \alpha$ 的置信区间为 $[\frac{x_{(n)}}{b}, \frac{x_{(n)}}{a}]$

故构造出的 N 的置信水平为 $1-\alpha$ 的置信上限为 $\frac{x_{(n)}}{a}$ 。

4.6

解:

由次序统计量的分布知, $X_{(n)}$ 的概率分布是:

$$P(X_{(n)} = k) = \frac{1}{N^n} [k^n - (k-1)^n], 1 \leq k \leq n$$

再由 $X_{(n)}$ 为 N 的充分统计里, 有

$$G(x_{(n)}, N) = P_N(X_{(n)} < x_{(n)}) = \sum_{k=1}^{[x_{(n)}]} \frac{1}{N^n} [k^n - (k-1)^n]$$

从而, $G(x_{(n)}, N)$ 为 N 的严格减函数。

所以, N 的 $1-\alpha$ 置信上限为

$$\hat{N}_n = \inf\{N : P_N(X_{(n)} < x_{(n)} \leq \alpha)\}.$$

4.6 设总体 X 是点集 $\{1, 2, \dots, N\}$ 的均匀分布, 其中 N 为未知参数. 设 $X = (X_1, \dots, X_n)$ 是来自 X 的样本. 令 $X_{(n)} = \max\{X_1, \dots, X_n\}$. 试基于 $X_{(n)}$ 构造 N 的置信水平 $1-\alpha$ 的置信上限。

解: 因为总体 X 是点集 $\{1, 2, \dots, N\}$ 的均匀分布, 则总体概率分布为:

$$P(X = k) = \frac{1}{N}, \quad k = 1, 2, \dots, N$$

$$\text{其分布函数为 } F(x) = \frac{k}{N}, \quad k \leq x < k+1 \quad (k = 1, 2, \dots, N)$$

从而次序统计量 $X_{(n)}$ 的概率分布为:

$$P(X_{(n)} = k) = \frac{1}{N^n} (k^n - (k-1)^n), \quad k = 1, 2, \dots, N$$

又 $X_{(n)}$ 为 N 的充分统计量, 从而

$$G(x_{(n)}, N) = P_N(X_{(n)} \leq x_{(n)}) = \sum_{i=1}^{x_{(n)}} \frac{1}{N^n} (k^n - (k-1)^n)$$

由此, $G(x_{(n)}, N)$ 为关于 N 的严格单减函数, 由定理 4.2 知, N 的置信水平 $1-\alpha$ 的置信上限为 $\hat{N}_U = \inf\{N : G(X_{(n)}, N) \leq \alpha\}$.

4.14

由题4.4, 当 x 大于0时,

$$P(X_{(1)} > x) = \{P(X > x)\}^n = \exp\{-n(x - \theta)\}$$

$$f(X_{(1)} = x) = n \cdot \exp\{-n(x - \theta)\}$$

$$\text{令 } e = X_{(1)} - \theta$$

$$\text{有 } f(e) = n \cdot \exp(-ne)$$

因此 $\theta = X_{(1)} - e$, 将 $e = X_{(1)} - \theta$ 代入

得 $P(\theta) = n \cdot \exp\{-n(X_{(1)} - \theta)\}$ 为 θ 的信仰分布

$P(\theta)$ 关于 θ 单增, 考虑信仰水平为 $1-a$ 的区间估计 $[\hat{\theta}_L, X_{(1)}]$

$$P(\theta \leq \hat{\theta}_L) = a, \int_{-\infty}^{\hat{\theta}_L} P(\theta) d\theta = a$$

$$\text{得 } \hat{\theta}_L = X_{(1)} + \frac{\ln a}{n}$$

选取常数 $c, d, d - c = 1 - a$

$$\text{有 } P_\theta = (c \leq 1 - \exp\{1 - n(X_{(1)} - \theta)\} \leq d) = 1 - a$$

这里取 $c = 0, d = 1 - a$, 置信水平为 $1 - a$ 的区间估计为 $\left[X_{(1)} + \frac{\ln a}{n}, X_{(1)}\right]$

因此信仰水平为 $1 - a$ 的区间估计是置信水平为 $(1 - a)$ 的区间估计

5.1

解: 状态集为 $\Theta = \{\theta_1, \theta_2\}$, 其中 θ_1 表示“不下雨”, 其中 θ_2 表示“下雨”。

行动集为 $\Delta = \{a_1, a_2\}$, 其中 a_1 表示“不开工”, 其中 a_2 表示“开工”。

$$Q = \begin{matrix} & \begin{matrix} a_1 & a_2 \end{matrix} \\ \begin{pmatrix} -4 & 30 \\ -4 & -12 \end{pmatrix} & \begin{matrix} \theta_1 \\ \theta_2 \end{matrix} \end{matrix}$$

所以收益矩阵为:

5.2

解：由题可知，该零件的更换次数 θ 和采购量 a 的可能取值是一切非负整数。所以，

$$\Theta=\Delta=\{0,1,2,\dots,n,\dots\}$$

由此可以写成收益函数如下，

$$Q(\theta,a)=\begin{cases} -(250a+750(\theta-a)) & a < \theta \\ -250a & a \geq \theta \end{cases}$$

又由 $L(\theta,a)=\max Q(\theta,a)-Q(\theta,a)$ ，可以写成损失函数如下，

$$L(\theta,a)=\begin{cases} 500(\theta-a) & a < \theta \\ 250(a-\theta) & a \geq \theta \end{cases}$$

若三年内最多需要4个备用零件则， $\Theta=\Delta=\{0,1,2,3,4\}$

所以收益矩阵和损失矩阵如下

$$Q=\begin{matrix} & \begin{matrix} a_1=0 & a_2=1 & a_3=2 & a_4=3 & a_5=4 \end{matrix} \\ \begin{pmatrix} 0 & -250 & -500 & -750 & -1000 \\ -750 & -250 & -500 & -750 & -1000 \\ -1500 & -1000 & -500 & -750 & -1000 \\ -2250 & -1750 & -1250 & -750 & -1000 \\ -3000 & -2500 & -2000 & -1500 & -1000 \end{pmatrix} & \begin{matrix} \theta_1=0 \\ \theta_2=1 \\ \theta_3=2 \\ \theta_4=3 \\ \theta_5=4 \end{matrix} \end{matrix}$$

$$L=\begin{matrix} & \begin{matrix} a_1=0 & a_2=1 & a_3=2 & a_4=3 & a_5=4 \end{matrix} \\ \begin{pmatrix} 0 & 250 & 500 & 750 & 1000 \\ 500 & 0 & 250 & 500 & 750 \\ 1000 & 500 & 0 & 250 & 500 \\ 1500 & 1000 & 500 & 0 & 250 \\ 2000 & 1500 & 1000 & 500 & 0 \end{pmatrix} & \begin{matrix} \theta_1=0 \\ \theta_2=1 \\ \theta_3=2 \\ \theta_4=3 \\ \theta_5=4 \end{matrix} \end{matrix}$$

5.3

依题意，在该问题中状态集 Θ 和行动集 Δ 均为区间 $[0,1]$ ，当 $a < \theta$ 时会导致供不应求，当 $a > \theta$ 时会导致供过于求，故厂长所用的损失函数为

$$L(\theta,a)=\begin{cases} 2(a-\theta), 0 \leq \theta < a \\ \theta-a, a \leq \theta \leq 1 \end{cases}$$

5.4

依题意，令 $b_1+m_1\theta=b_2+m_2\theta$ ，解得 $\theta=(b_1-b_2)/(m_2-m_1)$ ，

且当 $\theta > (b_1 - b_2)/(m_2 - m_1)$ 时, $b_1 + m_1 \theta > b_2 + m_2 \theta$;

当 $\theta < (b_1 - b_2)/(m_2 - m_1)$ 时, $b_1 + m_1 \theta < b_2 + m_2 \theta$

又行动 a 所引起的损失为

$$L(\theta, a) = \max_{a \in \Delta} Q(\theta, a) - Q(\theta, a)$$

综上, 二行动线性决策问题的损失函数为

$$L(\theta, a_1) = \begin{cases} (b_2 - b_1) + (m_2 - m_1)\theta, & \theta \leq (b_1 - b_2)/(m_2 - m_1) \\ 0, & \theta > (b_1 - b_2)/(m_2 - m_1) \end{cases}$$

$$L(\theta, a_2) = \begin{cases} 0, & \theta \leq (b_1 - b_2)/(m_2 - m_1) \\ (b_1 - b_2) + (m_1 - m_2)\theta, & \theta > (b_1 - b_2)/(m_2 - m_1) \end{cases}$$

5.5

在缺少损失函数信息场合, 可用参数 θ 处的密度函数值 $p(x|\theta)$ 与在行动 a 处的密

度函数值 $p(x|a)$ 之间的距离来度量损失, 如下两个距离较为常用.

(1) 熵的距离: $Le(\theta, a) = E_{x|\theta} \left[\ln \frac{p(x|\theta)}{p(x|a)} \right];$

(2) Hellinger 距离: $L_H(\theta, a) = \frac{1}{2} E_{x|\theta} \left[\sqrt{\frac{p(x|a)}{p(x|\theta)}} - 1 \right]^2$, 假如 $X \sim N(\theta, 1)$, 证明:

$$Le(\theta, a) = \frac{1}{2} (a - \theta)^2$$

$$L_H(\theta, a) = 1 - \exp\{-(a - \theta)^2 / 8\}$$

证明 $p(x|\theta) = \frac{1}{\sqrt{2\pi}} \exp\{-\frac{1}{2}(x - \theta)^2\}$

$$\frac{p(x|\theta)}{p(x|a)} = \exp\left\{-\frac{1}{2}(a - \theta)(2x - \theta - a)\right\}, \quad \ln \frac{p(x|\theta)}{p(x|a)} = -\frac{1}{2}(a - \theta)(2x - \theta - a)$$

$$Le(\theta, a) = E_{x|\theta} \left[\ln \frac{p(x|\theta)}{p(x|a)} \right] = E_{x|\theta} \left[-\frac{1}{2}(a - \theta)(2x - \theta - a) \right] = -\frac{1}{2}(a - \theta)(2\theta - \theta - a)$$

$$= \frac{1}{2} (a - \theta)^2$$

$$L_H(\theta, a) = \frac{1}{2} E_{x|\theta} \left[\sqrt{\frac{p(x|a)}{p(x|\theta)}} - 1 \right]^2 = \frac{1}{2} \int_{-\infty}^{+\infty} \left(\frac{p(x|a)}{p(x|\theta)} - 2\sqrt{\frac{p(x|a)}{p(x|\theta)}} + 1 \right) p(x|\theta) dx$$

$$= \frac{1}{2} \int_{-\infty}^{+\infty} (p(x|a) - 2\sqrt{p(x|a)p(x|\theta)} + p(x|\theta)) dx$$

$$\begin{aligned}
&= 1 - \int_{-\infty}^{+\infty} \sqrt{p(x|a)p(x|\theta)} dx \\
&= 1 - \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}} \exp\left\{-\frac{1}{2}\left(x - \frac{\theta+a}{2}\right)^2 - \frac{1}{8}(a-\theta)^2\right\} dx \\
&= 1 - \exp\left\{-\frac{1}{8}(a-\theta)^2\right\} \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}} \exp\left\{-\frac{1}{2}\left(x - \frac{\theta+a}{2}\right)^2\right\} dx \\
&= 1 - \exp\{-(a-\theta)^2/8\}
\end{aligned}$$